

Sistemas Recomendadores

IIC-3633



Recomendación basada en contenido
Parte 2

Esta clase

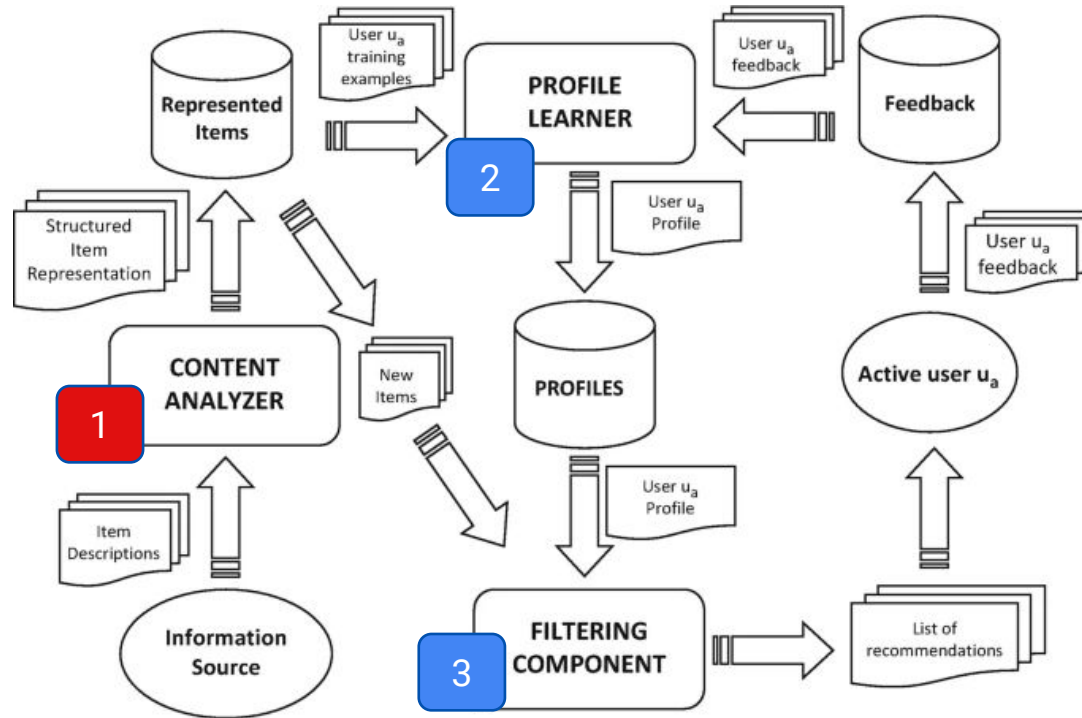
1. Recomendación basada en contenido (tag-based recommendation)
2. Recomendación basada en contenido imágenes

Filtrado basado en contenido

El filtrado basado en contenido involucra la creación de un perfil de usuario basado en sus preferencias y la recomendación de contenido similar al que el usuario ha valorado positivamente en el pasado.

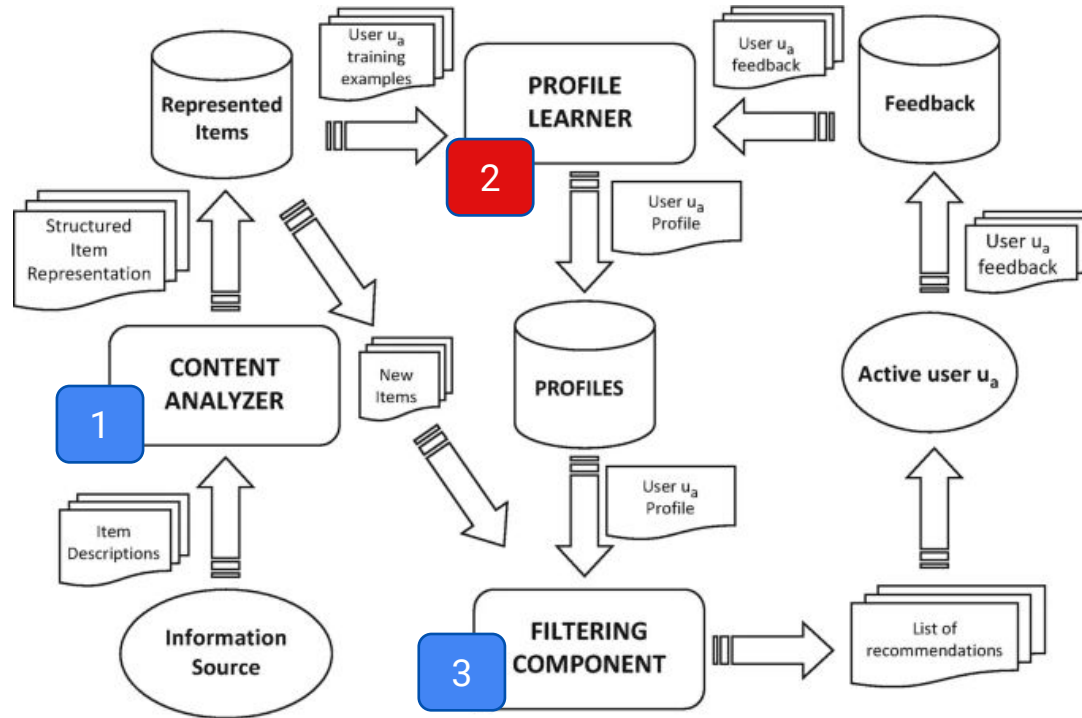


Arquitectura general de un sistema basado en contenido



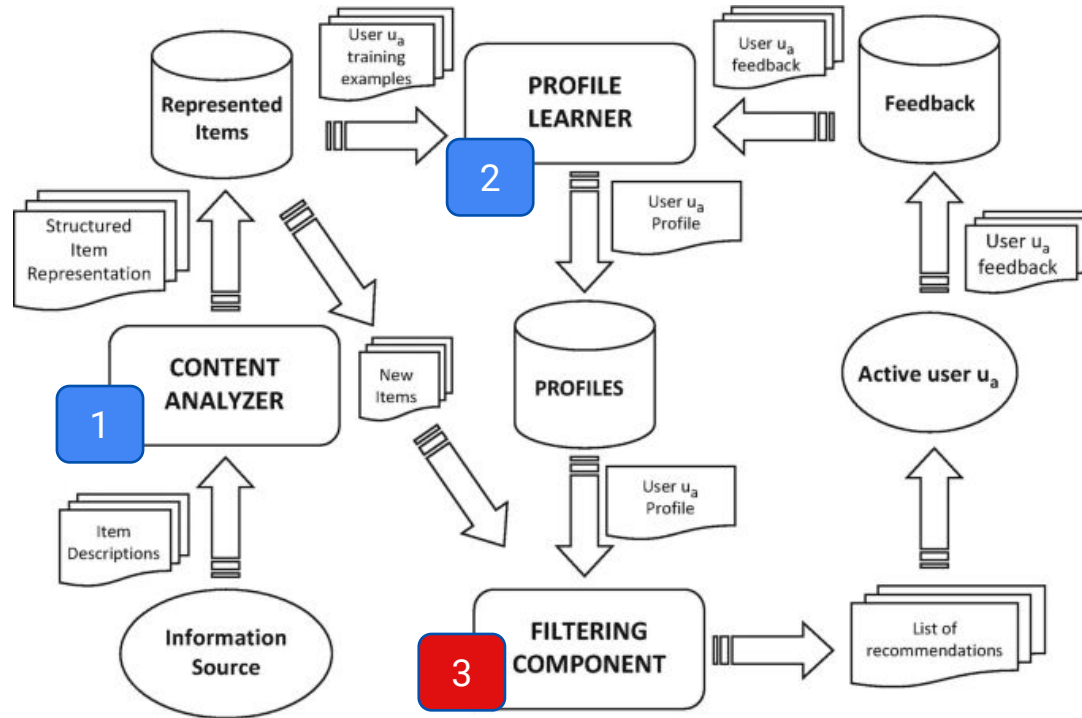
De Gemmis, M., Lops, P., Musto, C., Narducci, F., & Semeraro, G. (2015). Semantics-aware content-based recommender systems. *Recommender systems handbook*, 119-159.

Arquitectura general de un sistema basado en contenido



De Gemmis, M., Lops, P., Musto, C., Narducci, F., & Semeraro, G. (2015). Semantics-aware content-based recommender systems. *Recommender systems handbook*, 119-159.

Arquitectura general de un sistema basado en contenido



De Gemmis, M., Lops, P., Musto, C., Narducci, F., & Semeraro, G. (2015). Semantics-aware content-based recommender systems. *Recommender systems handbook*, 119-159.

YouTube CL Search

The best talent in tennis in history ATP - Marcelo Rios

291,865 views

1K 153 SHARE SAVE ...

j **juan carlos**
Published on May 13, 2017

Marcelo Rios First player latin america to be number one in atp. great talent in tennis. 18 titles champion in:

SHOW MORE

748 Comments SORT BY

Add a public comment...

Patricio Aguilera 2 years ago
Destacó en un momento en que el tenis se había transformado en un bombardeo de aces; de pronto ¿Quién es este?... un capo. A los que critican, intenten ser número uno del mundo.

70 153 REPLY

View 35 replies

William Oliver D'ville 2 years ago
El Ronaldinho del Tenis! Talento puro que se concentró en pocos años, pero que hizo que muchos niños se encantaran con la actividad...

42 153 REPLY

View 3 replies

Marcelomauricio Pinto Bustamante 8 months ago (edited)

Up next

Rios Korda 98
UBchristennis
46K views

Chile 7 v/s México 0 - Relatos Mexicanos ¡Humillación total!
MauriliHD Producciones ©
6.4M views

SERGIO FREIRE triunfa en #VINA2018 - Festival de Viña...
FESTIVALDEVINACHILE
Recommended for you

Usain Bolt y los superdotados de la última década (100m...
Néstor Gustavo U.
4.2M views

Tie Break 4to Set, Final Dobles Tenis Atenas 2004
Cristián Olate Cornejo
495K views

Most Unorthodox Tennis Match Ever (50FPS)
FeatureTennis
4.7M views

McEnroe vs Connors - Semi Final US Open 1980 - 14/16
John McEnroe Channel
642K views

La Generación Dorada Chilena - Documental (Parte1)
MauriliHD Producciones ©
618K views

Marcelo Rios vs Jim Courier Singapur 1998
peluzon
133K views

ATP TENNIS Best Power shot in history - Fernando Gonzalez
Juan Carlos Saldias
791K views

5 Times Federer was RIGHT and the umpire was WRONG!
Tennis Time
1.6M views

El recomendado
del sitio Web
YouTube usa el
contenido de los
videos como pa
de los datos pa
hacer
recomendacion

YOUR INTEREST IN CLASSICS

updated: 0 minutes ago



Want to Read



Not interested



Want to Read




Not interested



Want to Read




Not interested



Want to Read



Not interested



Want to Read



Not interested

[More for this genre »](#)

El recomendador
de GoodReads
usa el contenido
de los libros y
metadatos para
hacer
recomendaciones.

resas como

fy usan

entes

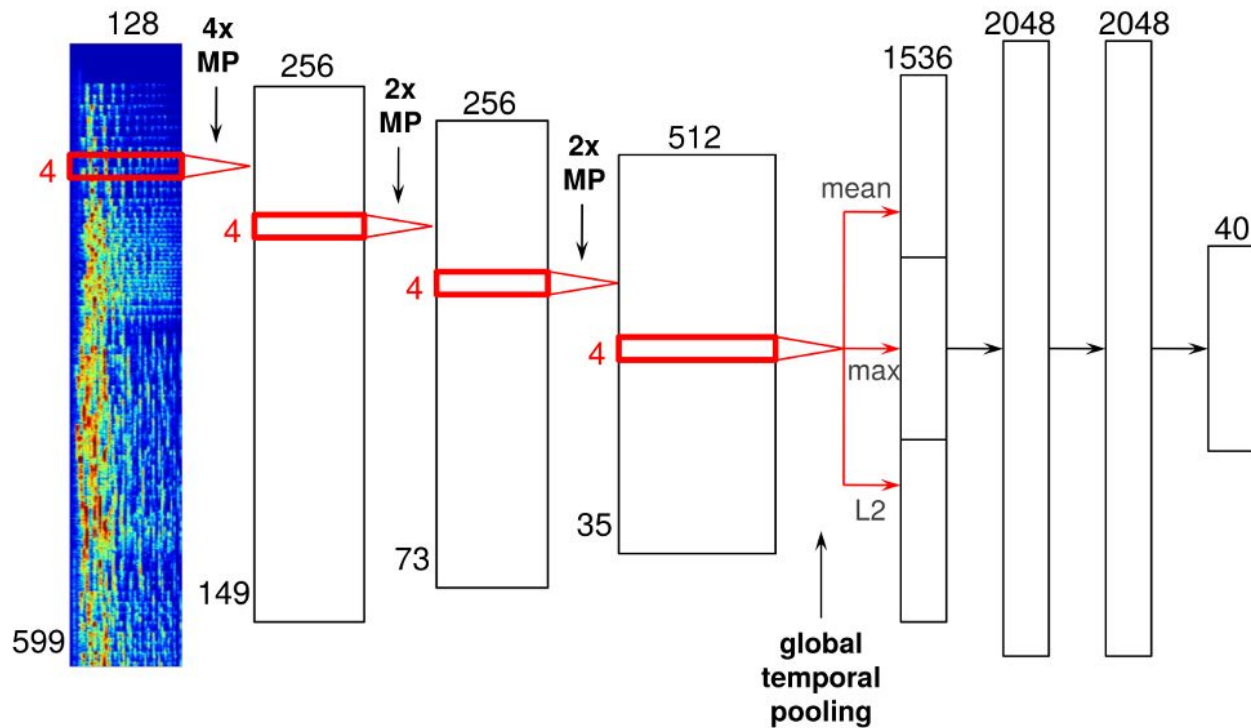
terísticas de

sica para


mendar, entre

el contenido

udio



El filtrado basado
en contenido
permite abordar el
problema de
nuevo ítem o “item
cold start”



Puede presentar
problemas al
abordar el cambio
de gusto de los
usuarios en el
tiempo



Recomendación basada en tags

Motivación

Es difícil obtener retroalimentación explícita del usuario.

En los social tagging systems el usuario provee de etiquetas (tags) en forma de feedback.

Los tags pueden ser metadata de los ítems (ej. conceptos clave).

Tags example (OpenAlex Scientific Articles Database)

💡 Concept

Computer science

Study of computation. ([Wikipedia](#))

🕒 level

Main Concept

[VIEW IN API](#)

Identifiers

- **openalex:** <https://openalex.org/C41008148>
- **wikidata:** <https://www.wikidata.org/wiki/Q21198>
- **mag:** 41008148
- **wikipedia:** <https://en.wikipedia.org/wiki/Computer%20science>
- **umls_cui:** ["C0599726"]

Tags (Concept metadata)

93 related concepts

🕒 Mathematics 🕒 Electrical engineering 🕒 Physics 🕒 Engineering 🕒 Mechanical engineering 🕒 Artificial intelligence 🕒 Algorithm 🕒 Biology 🕒 Civil engineering 🕒 Chemistry 🕒 Economics 🕒 Psychology

🕒 Programming language 🕒 Electronic engineering 🕒 Computer engineering 🕒 Software engineering 🕒 Social science 🕒 Philosophy 🕒 Statistics 🕒 Applied mathematics 🕒 Theoretical computer science 🕒 Political science

🕒 Database 🕒 Machine learning 🕒 Management 🕒 Cognitive science 🕒 Humanities 🕒 Chemical engineering 🕒 Industrial engineering 🕒 Biotechnology 🕒 Computer network 🕒 Distributed computing 🕒 Accounting

🕒 Bioinformatics 🕒 Business administration 🕒 Parallel computing 🕒 Human-computer interaction 🕒 Computer graphics (images) 🕒 Materials science 🕒 Environmental science 🕒 Operations research 🕒 Communication 🕒 Finance

🕒 Systems engineering 🕒 Computer security 🕒 Computer vision 🕒 Biomedical engineering 🕒 Nursing 🕒 Combinatorics 🕒 Computer architecture 🕒 Computational biology 🕒 Natural language processing 🕒 Commerce

Social tagging (CiteUlike)

The screenshot displays the CiteUlike web application in a Mozilla Firefox browser. The browser's address bar shows the URL <http://www.citeulike.org/user/denisparra>. The page header includes the CiteUlike logo, a "sponsored by Springer" banner, and a navigation bar with "CiteUlike", "MyCiteUlike", "Search", and "Logged in as denisparra" links. The main content area is titled "My library 83 articles" and lists several articles. The first article, "Information Resources: Search and Ranking", is highlighted with a red circle and the label "Resource". The second article, "Tag-LDA for Scalable Real-time Tag Recommendation", is also highlighted with a red circle and the label "Resource". The third article, "An algorithmic framework for performing collaborative filtering", is highlighted with a red circle and the label "Resource". The fourth article, "Evaluating collaborative filtering recommender systems", is highlighted with a red circle and the label "Resource". On the right side of the page, there is a section titled "denisparra's tags" which lists various tags and their frequencies. The tag "tags" is highlighted with a red circle and the label "Tags".

User

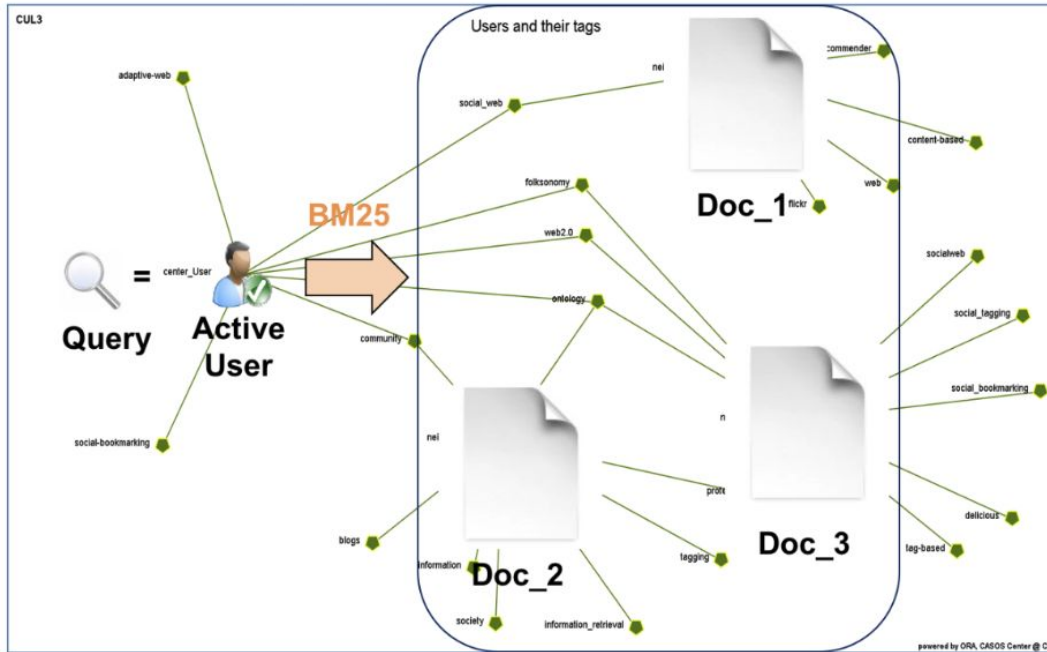
Resource

Tags

denisparra's tags

Tag	Frequency
recommender	11
collaborative-filtering	11
spreading-activation	7
lecture-2	7
social-tagging	6
adaptive-hypermedia	6
social-bookmarking	6
lecture-5	5
tag-based	4
lecture-4	4
tags	4
folksonomy	4
user-model	4
spread-activation	4
tag-recommendation	4
user-model-in-system	3

Tag-based collaborative filtering



Búsqueda de similitud por tags

BM25: Obtenemos la similitud entre usuarios considerando el conjunto de tags de un vecino como un "documento" y los tags del active user como la query.

Usamos Okapi BM25 **Retrieval Status Value** como medida de similitud.

$$sim(u, v) = RSV_d = \sum_{t \in q} IDF \cdot \frac{(k_1 + 1)tf_{td}}{k_1((1 - b) + b \times (L_d / L_{ave})) + tf_{td}} \cdot \frac{(k_3 + 1)tf_{tq}}{k_3 + tf_{tq}}$$

Tag frequency in the neighbor (v) profile

Tag frequency in the active user (u) profile

$$pred'(u, i) = \log_{10}(1 + nbr(i)) \cdot pred(u, i)$$

A Tag-Based Post-Hoc Framework for Explainable Conversational Recommendation

Kerui Xu

Beijing University of Posts and
Telecommunications
xukerui@bupt.edu.cn

Jun Xu*

Gaoling School of Artificial
Intelligence
Renmin University of China
junxu@ruc.edu.cn

Sheng Gao[†]

Beijing University of Posts and
Telecommunications
gaosheng@bupt.cn

Si Li

Beijing University of Posts and
Telecommunications
lisi@bupt.edu.cn

Jun Guo

Beijing University of Posts and
Telecommunications
guojun@bupt.edu.cn

Ji-Rong Wen

Gaoling School of Artificial
Intelligence
Renmin University of China
jrwen@ruc.edu.cn

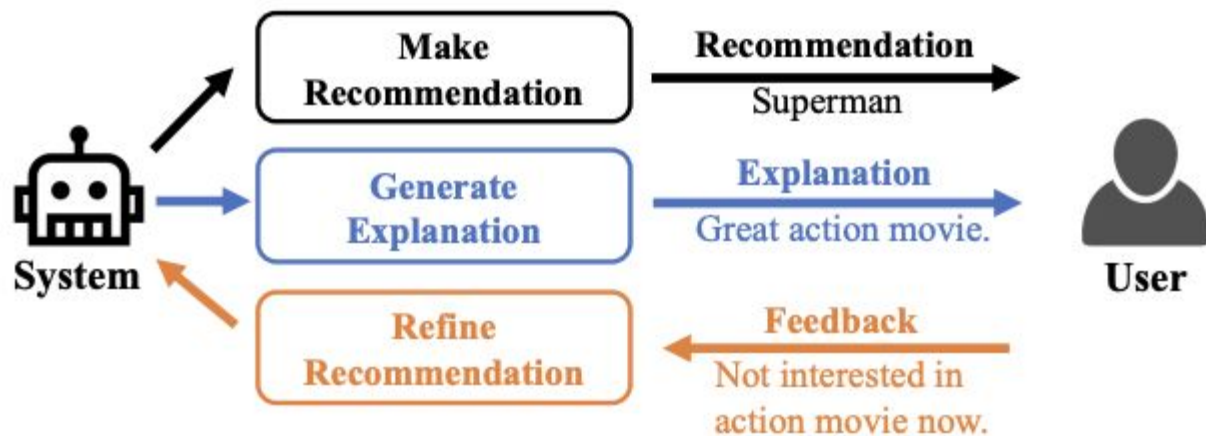


Figure 1: Pipeline of Explainable Conversational Recommendation. (Recommended Movie: Superman, Tag: Action)

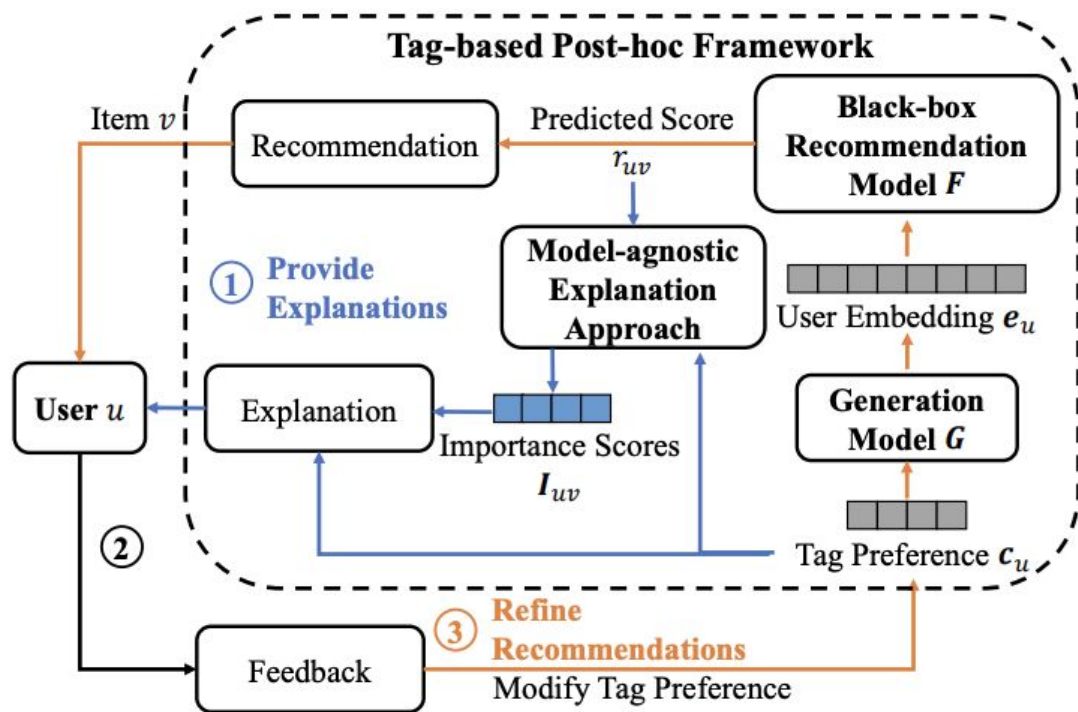


Figure 2: Overview of TPECR framework.

Recomendación utilizando contenido de
imágenes

Recomendación visual basada en contenido

En los modelos tradicionales de extracción de características a partir de imágenes se realizan con diferentes técnicas.

Algunas de ellas:

- Local Binary Patterns: método semi-manual usado como baseline para tareas de Visión por Computador.
- Obtiene un histograma de 59 patrones encontrados en una imagen.
- En base a 7 métricas.




Figure 1: The first step in constructing a LBP is to take the 8 pixel neighborhood surrounding a center pixel and threshold it to construct a set of 8 binary digits.




Figure 2: Taking the 8-bit binary neighborhood of the center pixel and converting it into a decimal representation. (Thanks to Bikramjot of [Hanzra Tech](#) for the inspiration on this visualization!)


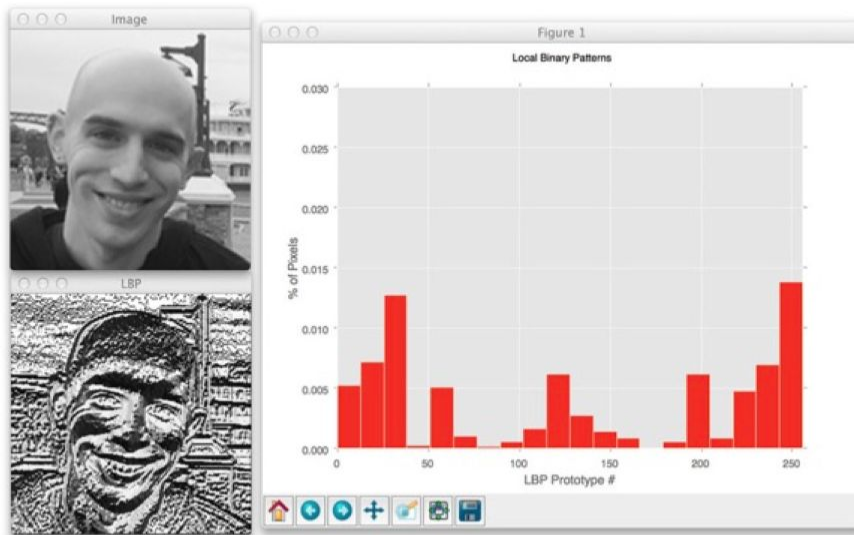


Figure 3: The calculated LBP value is then stored in an output array with the same width and height as the original image.

LBP: LOCAL BINARY PATTERNS

- Finalmente se calcula un histograma que tabula el número de ocasiones en que cada patron LBP ocurrió.
- Podemos pensar en este histograma como un vector de features.



Fuente: <https://www.pyimagesearch.com/2015/12/07/local-binary-patterns-with-python-opencv/>

Características visuales atractivas

San Pedro y Sierdorfer (2009) estudiaron características para caracterizar imágenes por su atractivo visual:

- Brightness (brillo)
- Saturación (saturation)
- Sharpness (nitidez)
- RMS-contrast (contraste RMS)
- Colorfulness (colorido)
- Naturalness (naturalidad)
- Entropy (entropía)

Jose San Pedro and Stefan Siersdorfer. 2009. Ranking and classifying attractiveness of photos in folksonomies. In Proceedings of the 18th international conference on World wide web (WWW '09).

Attractive


animal



landscape



portrait



flower



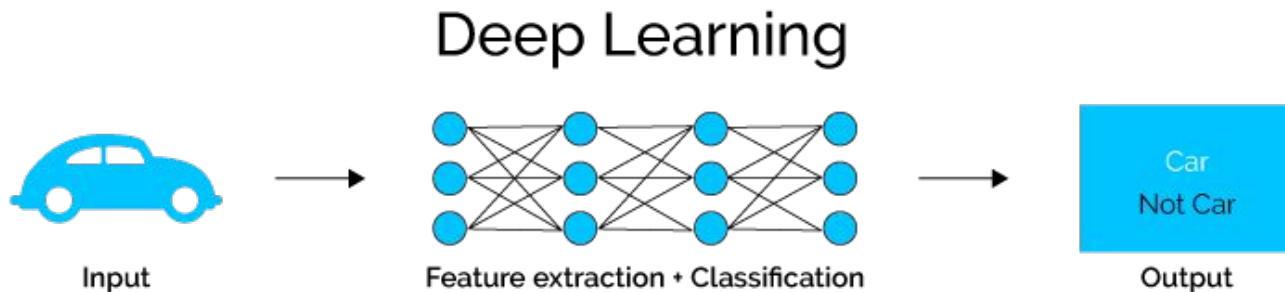

Unattractive



Figure 1: “Attractive” (upper row) vs. “Unattractive” (lower row) images: Each column represents the same semantic concept (animal, landscape, portrait, flower) but differences in appeal-related visual attributes.


¿Por qué usar redes neuronales para
representar imágenes?

¿Por qué deep learning?




Features manuales versus Deep Learning

- Con DL podemos usar features aprendidas automáticamente con una red neuronal pre-entrenada para otra tarea: clasificación de objetos del dataset Imagenet.



Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). Imagenet classification with deep convolutional neural networks. In *Advances in neural information processing*

¿Cómo podemos entonces capturar esta información de manera automática sin feature engineering?



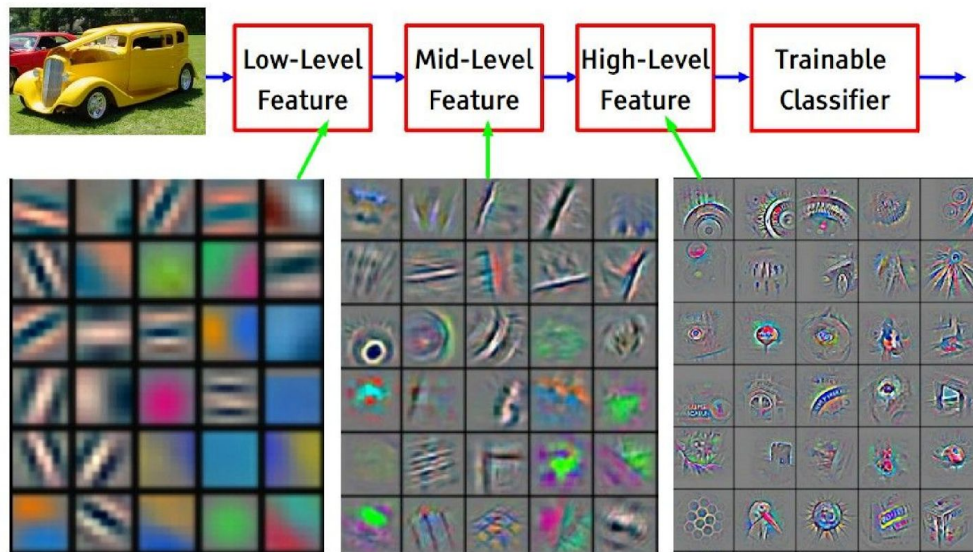
Neuronas capaces de barrer la entrada proveen una reducción significativa en el número de parámetros (no depende de la conectividad)

Además, dado su tamaño, permiten capturar patrones locales en cualquier posición.

¿Cómo podemos entonces capturar esta información de manera automática sin feature engineering?

Preview


*[From recent Yann
LeCun slides]*



Feature visualization of convolutional net trained on ImageNet from [Zeiler & Fergus 2013]

Redes neuronales convolucionales profundas

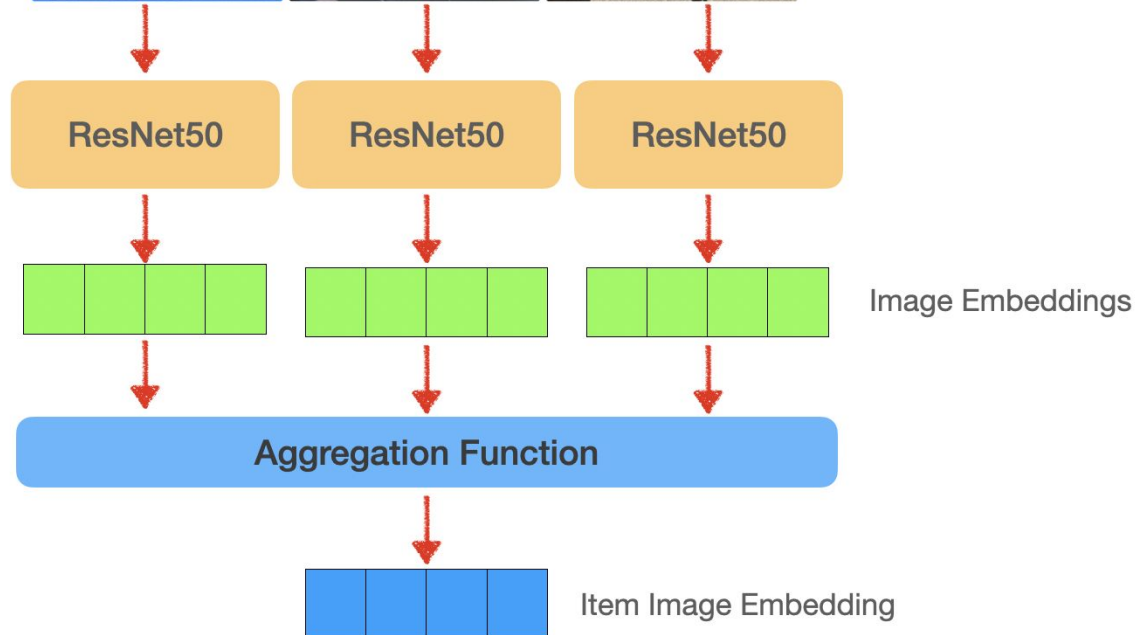
- Están formadas por capas convolucionales, de pooling y fully connected (MLP).
- Sustituyen la mayoría de las capas densas (fully connected) de los MLP, por capas convolucionales.
- Disminuyen drásticamente el número de parámetros, en comparación con los MLP.
- Sustentadas en bases biológicas (neuronas reales)




EMBEDDING



Photos for Street Burger

All (29) Food (18) Outside (6) Inside (2) Menu (1)






Item text embedding



...

Item image embedding



...

TOP 3

Fuente Alemana
0.7

Burguesia
0.65

Jose Ramon 277
0.63

TOP 3

Albedrío
0.82

Mc Donalds
0.75

Fuente Alemana
0.63

Ideas proyectos

Incorporación de representaciones estructurales relacionales de grafos para el problema de recomendación de libros

Luciano Hidalgo
Pontificia Universidad Católica de
Chile
lhidalgo1@uc.cl

Carlos Muñoz
Pontificia Universidad Católica de
Chile
carlos.munoz@uc.cl

Tamara Quiroga
Pontificia Universidad Católica de
Chile
t.quiroga@uc.cl

ABSTRACT

El portal Amazon cuenta con más de 33 millones de libros y agrega más de 50 mil nuevos cada mes. Para un usuario común y corriente explorar este espacio de búsqueda sin herramientas que vayan aprendiendo sus intereses resultaría imposible. En virtud de ello, el problema de la recomendación de libros representa un terreno fértil para explorar técnicas nuevas para generar sugerencias de títulos a un usuario. En el ámbito de los sistemas de recomendación, las técnicas que incorporan representaciones de grafos en el modelo de recomendación han demostrado ser promisorias. Por esta razón, el trabajo presentado aquí explora la hipótesis de que el uso de representaciones de grafos permite obtener una mejor representación de las relaciones entre ítems y mejorar el rendimiento. Para ello, usando el *dataset Amazon Book Reviews* se intenta mejorar recomendaciones basadas en *K-Nearest Neighbors* y *Neural Matrix Factorization*, representando grafos de autor-libro, usuario-item y género-libro. Tras desarrollar los experimentos, los mejores resultados se obtuvieron con el enfoque usuario-item, mientras que autor-libro empeoró el rendimiento del modelo base y género-libro únicamente mejoró marginalmente las recomendaciones. Con esto se demuestra que para este problema, el uso de representaciones de grafos mejora la capacidad de recomendar, sin embargo, conlleva un aumento significativo del costo computacional para generar y procesar este tipo de estructuras.

1 INTRODUCCIÓN

Con más de 33 millones de títulos, la plataforma Amazon es el principal vendedor de libros del mundo tanto en formato físico como digital. Cada mes 50,000 libros nuevos son publicados para la venta en esta plataforma, dado este espacio posible de artículos disponibles, la navegación por el catálogo del Amazon no sería posible sin estrategias que permitan discriminar el contenido relevante para un usuario de aquel que no le genera interés. A raíz de esto, en el ámbito de la búsqueda y venta de libros, los Sistemas de Recomendación (RS), son vitales para el funcionamiento del negocio, pues estas ofrecen ayuda a tareas tales como: obtener artículos que a un usuario en particular podrían gustarle, dar a conocer las novedades que se han ido agregando a la plataforma o entender los perfiles de compra de los usuarios.

Los avances de los últimos años en métodos de aprendizaje de máquina y la incorporación de redes convolucionales profundas en problemas de representación de imágenes, texto y otros medios, han influido directamente en el campo de los sistemas de recomendación (RS) [1]. En esta línea, enfoques basados en aprendizaje reforzado [2], *Generative Adversarial Networks* [3], basados en conocimiento ontológico [4], entre otros han avanzado en proveer nuevas estrategias para recomendar contenido. En este escenario, las técnicas de recomendación basadas en grafos [5] parecen ser una fórmula prometedora para modelar relaciones que luego pueden explotarse para generar recomendaciones de contenido.

GRAPH EMBEDDINGS

- USER-ITEM
- AUTHOR-BOOK
- GENRE-BOOK




Figure 1: Modelo de extracción de representaciones por Graph2Vector

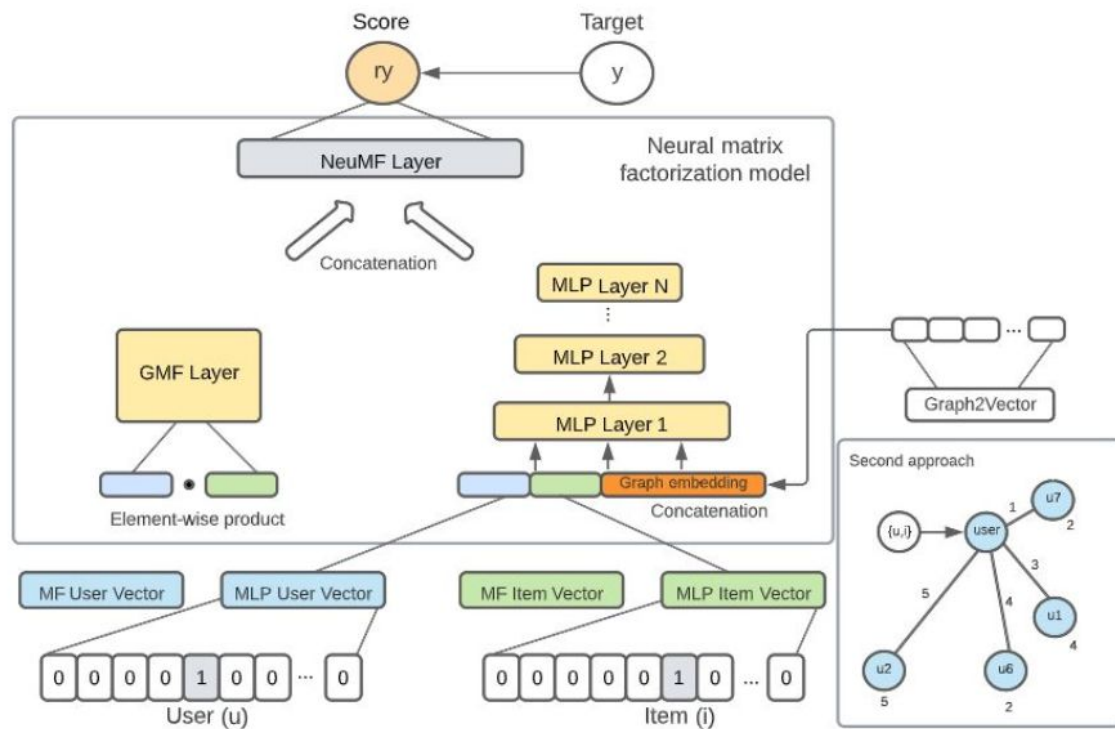


Figure 4: Arquitectura de red NeuMF con representación de grafos.

Received July 16, 2020, accepted July 27, 2020, date of publication August 3, 2020, date of current version August 13, 2020.

Digital Object Identifier 10.1109/ACCESS.2020.3013639

Aspect-Based Fashion Recommendation With Attention Mechanism

WEIQIAN LI ^{1,2} **AND BUGAO XU** ²

¹School of Computer Science, Xi'an Polytechnic University, Xi'an 710048, China

²Department of Merchandising and Digital Retailing, University of North Texas, Denton, TX 76203, USA

Corresponding author: Bugao Xu (bugao.xu@unt.edu)

