



PONTIFICIA  
UNIVERSIDAD  
CATÓLICA  
DE CHILE

# Active Learning en Sistemas Recomendadores

Denis Parra

IIC3633 – Sistemas Recomendadores

PUC Chile

# Active Learning en Sistemas Recomendadores

# Referencias

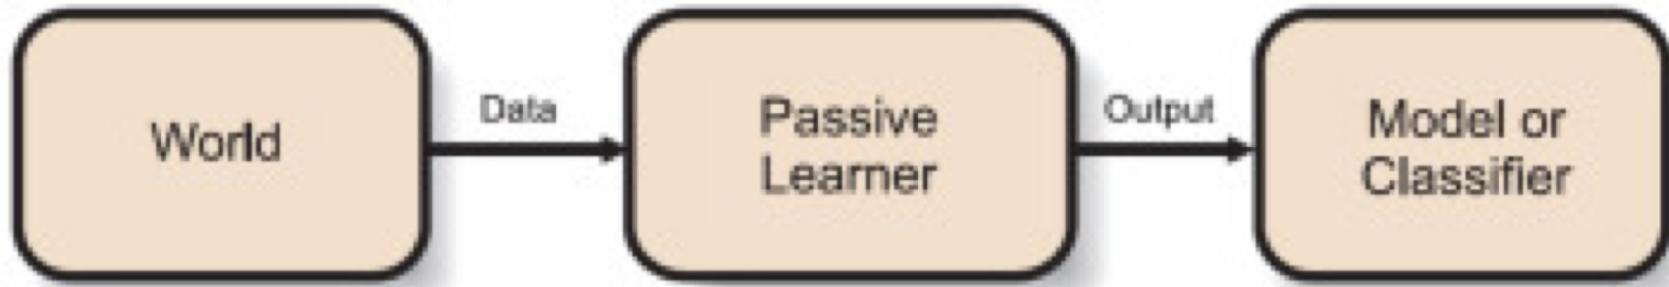
- Slides basadas principalmente en:

Mehdi Elahi, Francesco Ricci, Neil Rubens, **A survey of active learning in collaborative filtering recommender systems,**  
Computer Science Review, Volume 20, May 2016, Pages 29-50, ISSN 1574-0137,  
<http://dx.doi.org/10.1016/j.cosrev.2016.05.002>.  
(<http://www.sciencedirect.com/science/article/pii/S1574013715300150>)

# El Problema de Recomendación

- ... hasta ahora, es predecir ratings or rankear items dado un dataset existente
- Sin embargo, los sistemas evolucionan de forma dinámica
- Una estrategia de Aprendizaje Activo en Filtrado Colaborativo implica una estrategia precisa para seleccionar items de forma que el usuario provea ratings y eso nos permita mejorar nuestro sistema.

# Active Learning



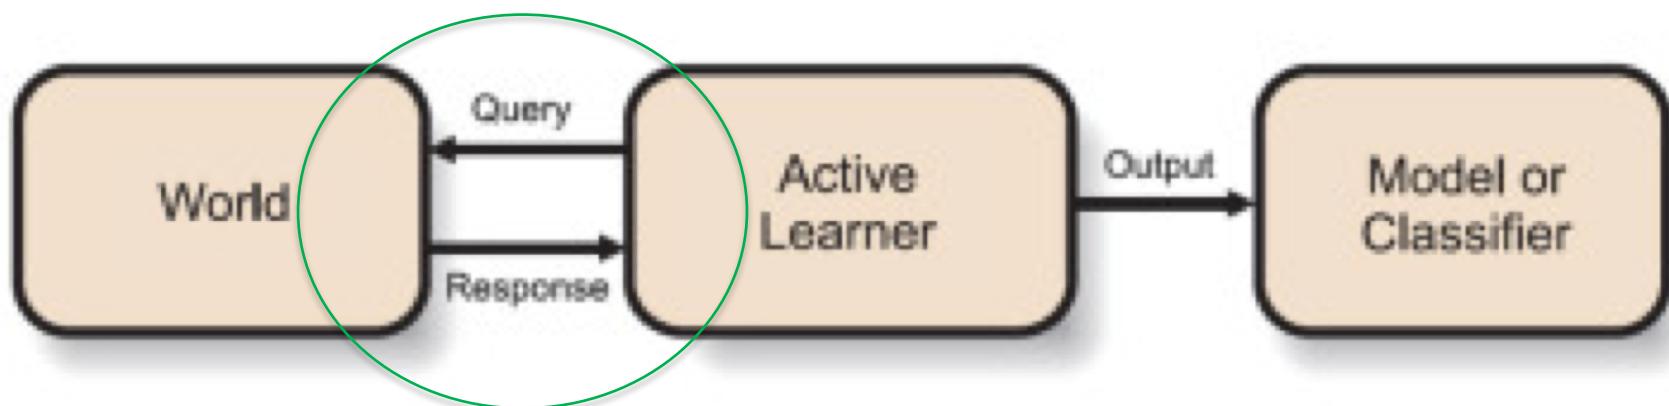
General schema for a passive learner.



General schema for an active learner.

# Active Learning

... el proceso de guiar el muestreo de datos a través de la consulta de ciertos tipos de instancias basado en los datos que el sistema ha visto hasta el momento.



General schema for an active learner.

# Algoritmo Genérico

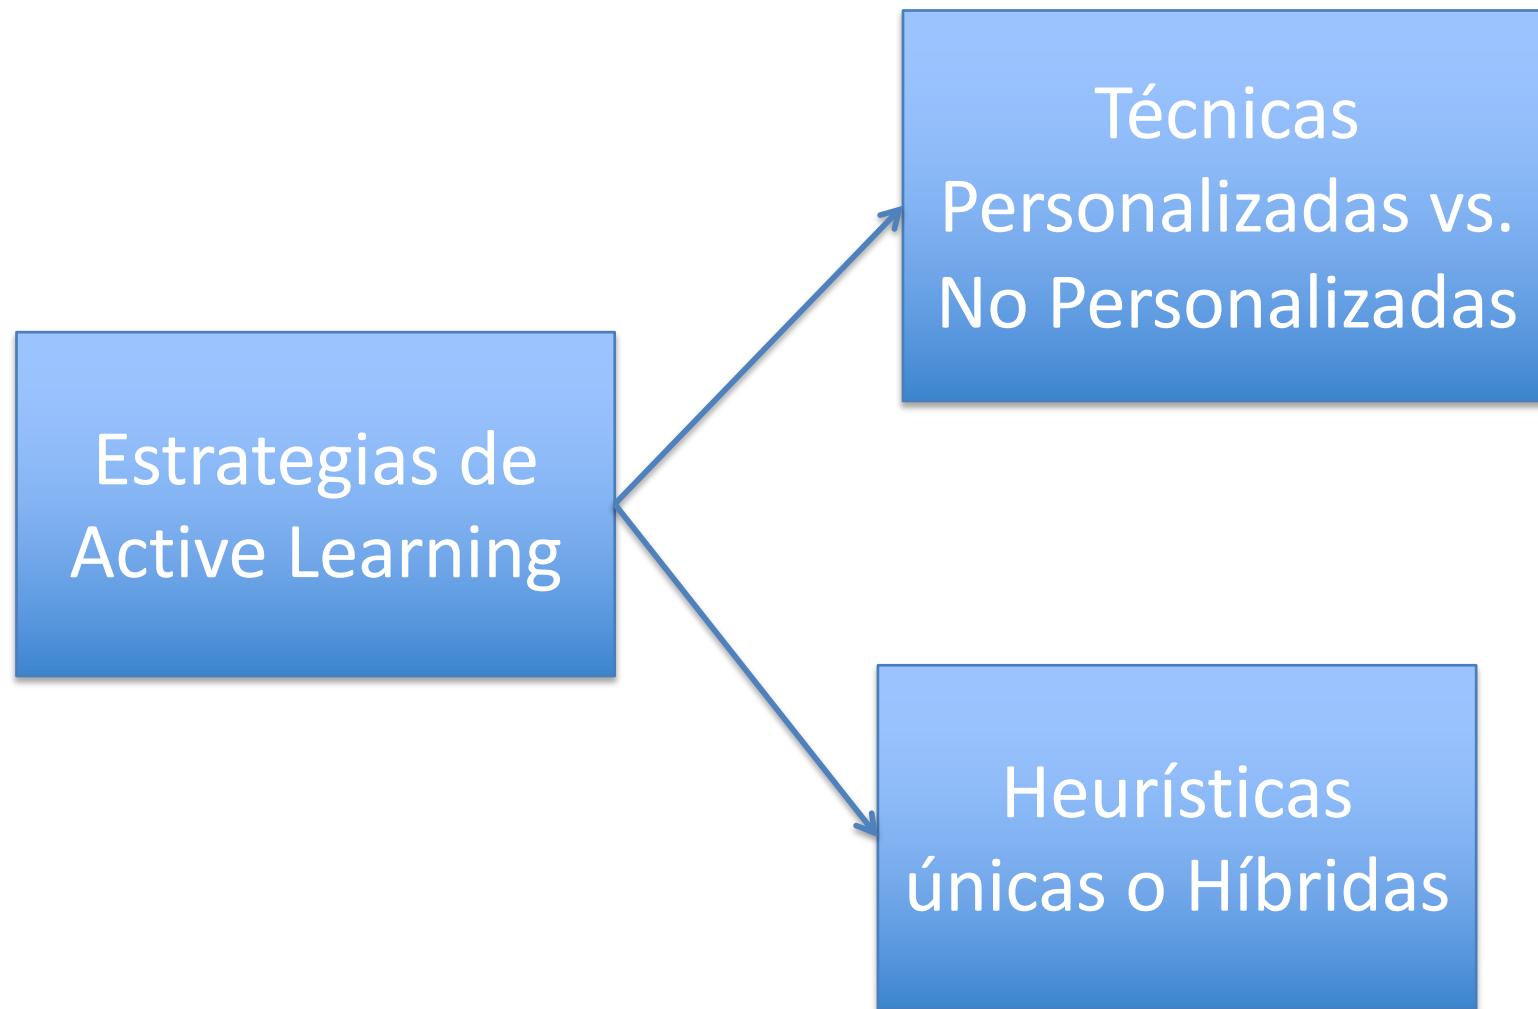
```
for  $j := 1$  to  $totalIterations$  do
    foreach  $q_j$  in  $potentialQueries$  do
        | Evaluate  $Loss(q_j)$ ;
    end
    Ask query  $q_j$  for which  $Loss(q_j)$  is the lowest;
    Update model  $\mathcal{M}$  with query  $q_j$  and response  $(q_j, y_j)$ ;
end
return model  $\mathcal{M}$ ;
```

**Algorithm 1:** General algorithm for Active Learning [58]

# A.L. en el problema de Recomendación

- New User
- New Item
- Costo de Obtener Feedback
- Adaptación de métodos de Aprendizaje Activo

# Clasificación de Técnicas Existentes



# Técnicas Personalizadas/No Personalizadas

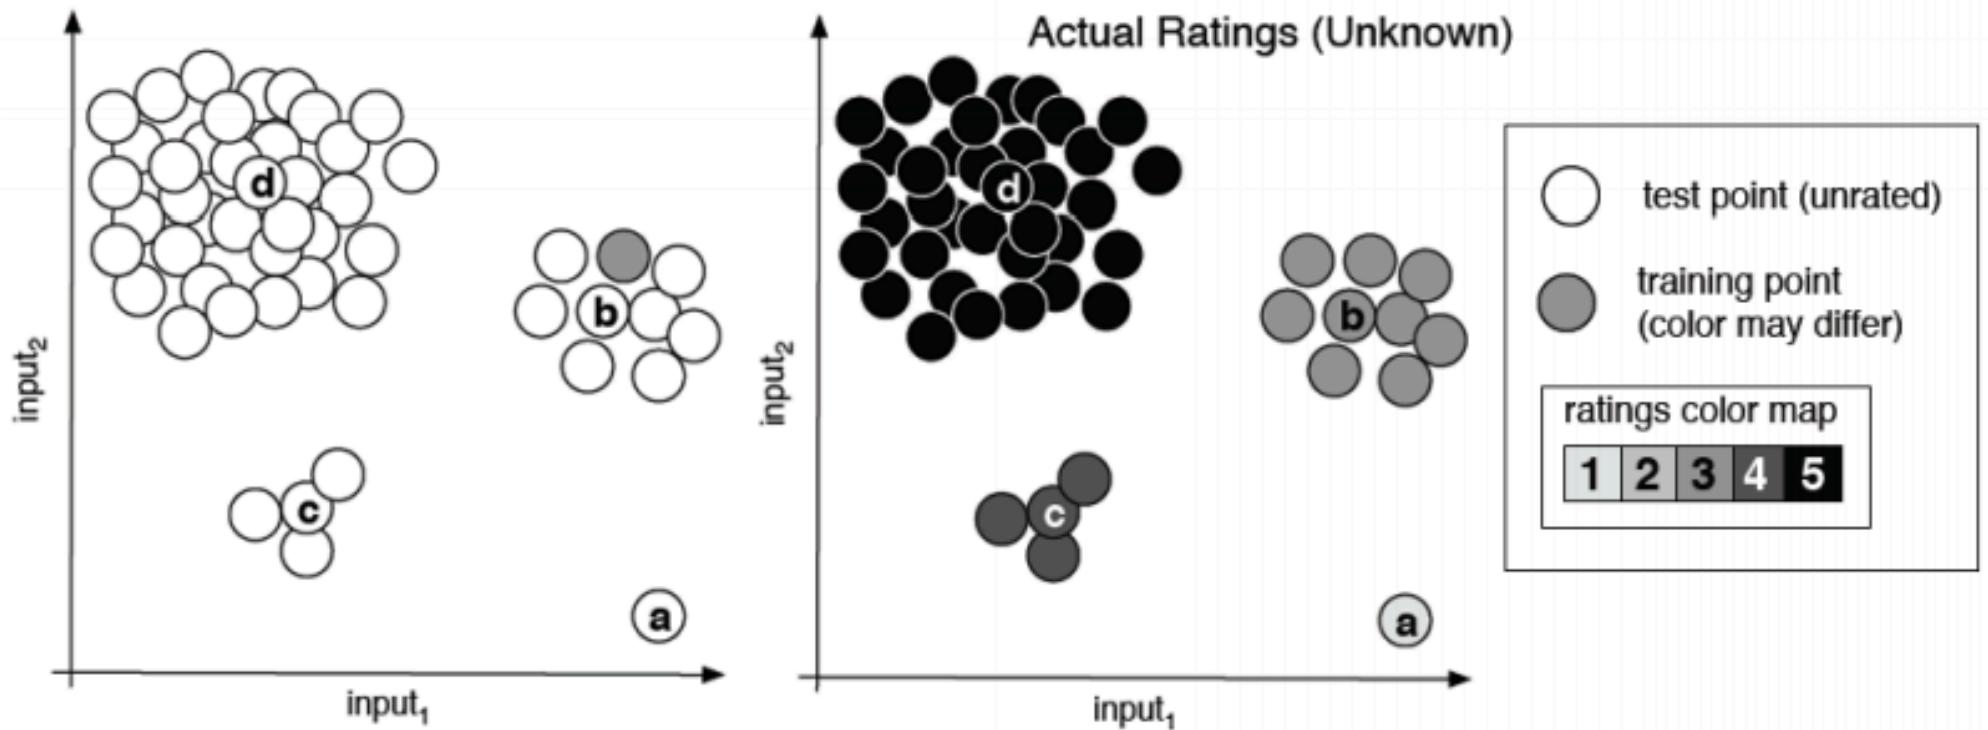
- **No Personalizadas:** Solicitar a los usuario dar feedback (ratings) a los mismos ítems. Esto podría ayudar a mejorar el sistema en general pero quizás en detrimento de preferencias de usuarios específicos.
- **Personalizadas:** Seleccionar los items considerando los gustos o preferencias del usuario, o que permitan de forma más efectiva obtener esta información.

# Herísticas únicas o Hibridizadas

- **Single-Heuristic:** Se considera sólo una regla de selección, la cual se utiliza para seleccionar items.
- **Combined-Heuristic:** Permiten contribuir una estrategia Híbrida al agregar o combinar varias opciones con potencial de mejorar el rendimiento del sistema y, por ende, ser usadas para ratings de usuarios.

# Ejemplo Ilustrativo

- ¿Qué película nos conviene escoger?

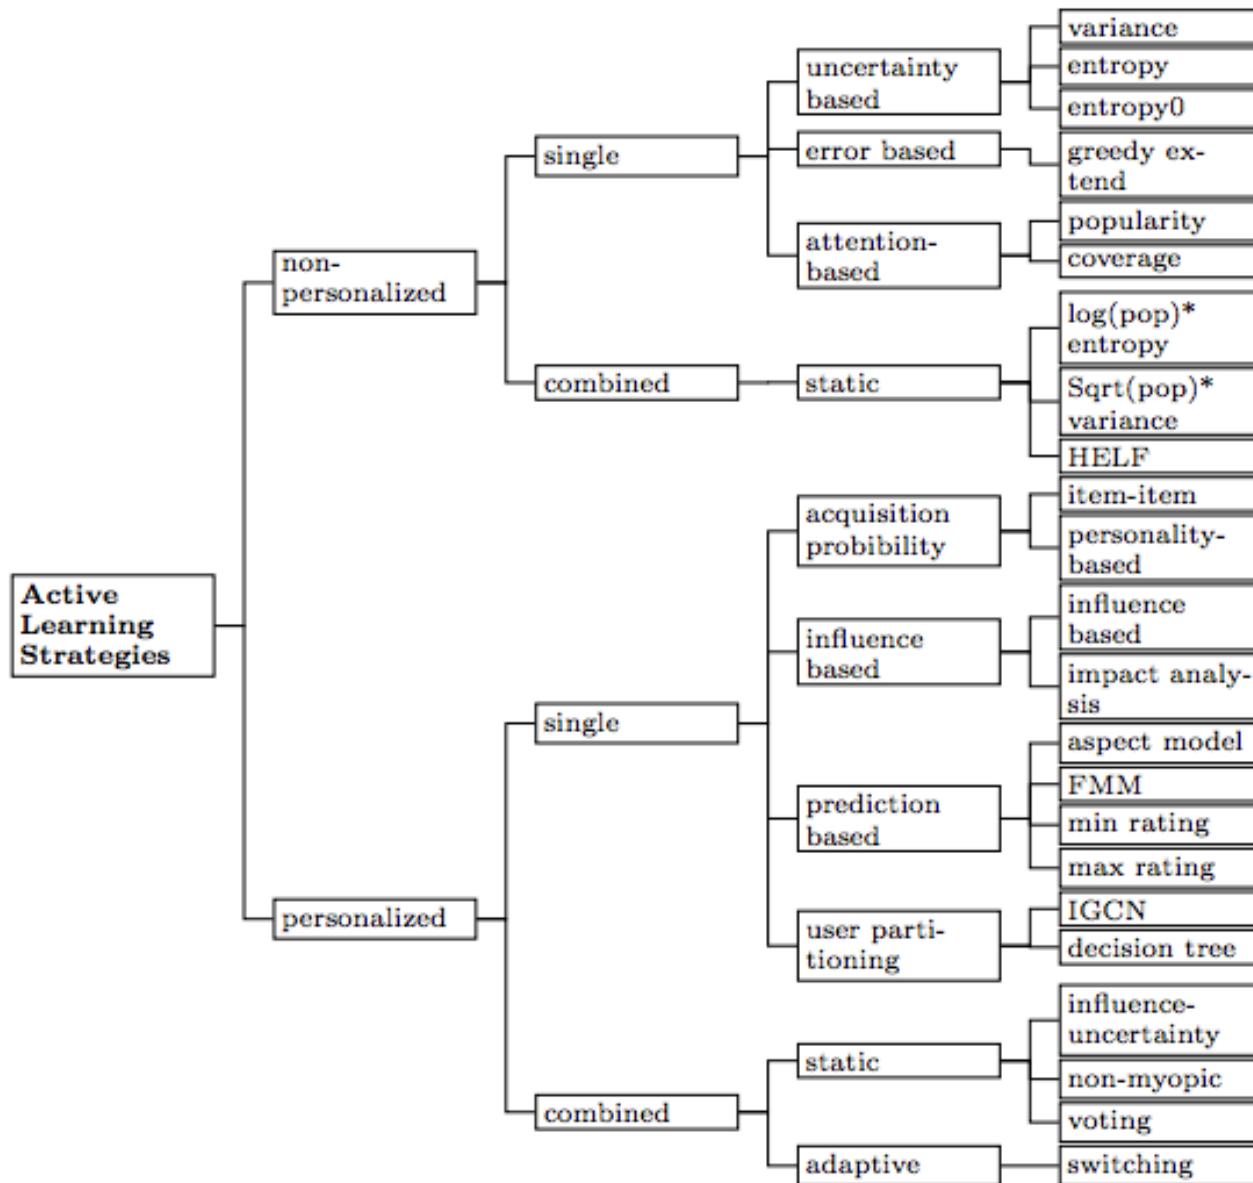


**Fig. 1.** Active learning, an illustrative example [19]

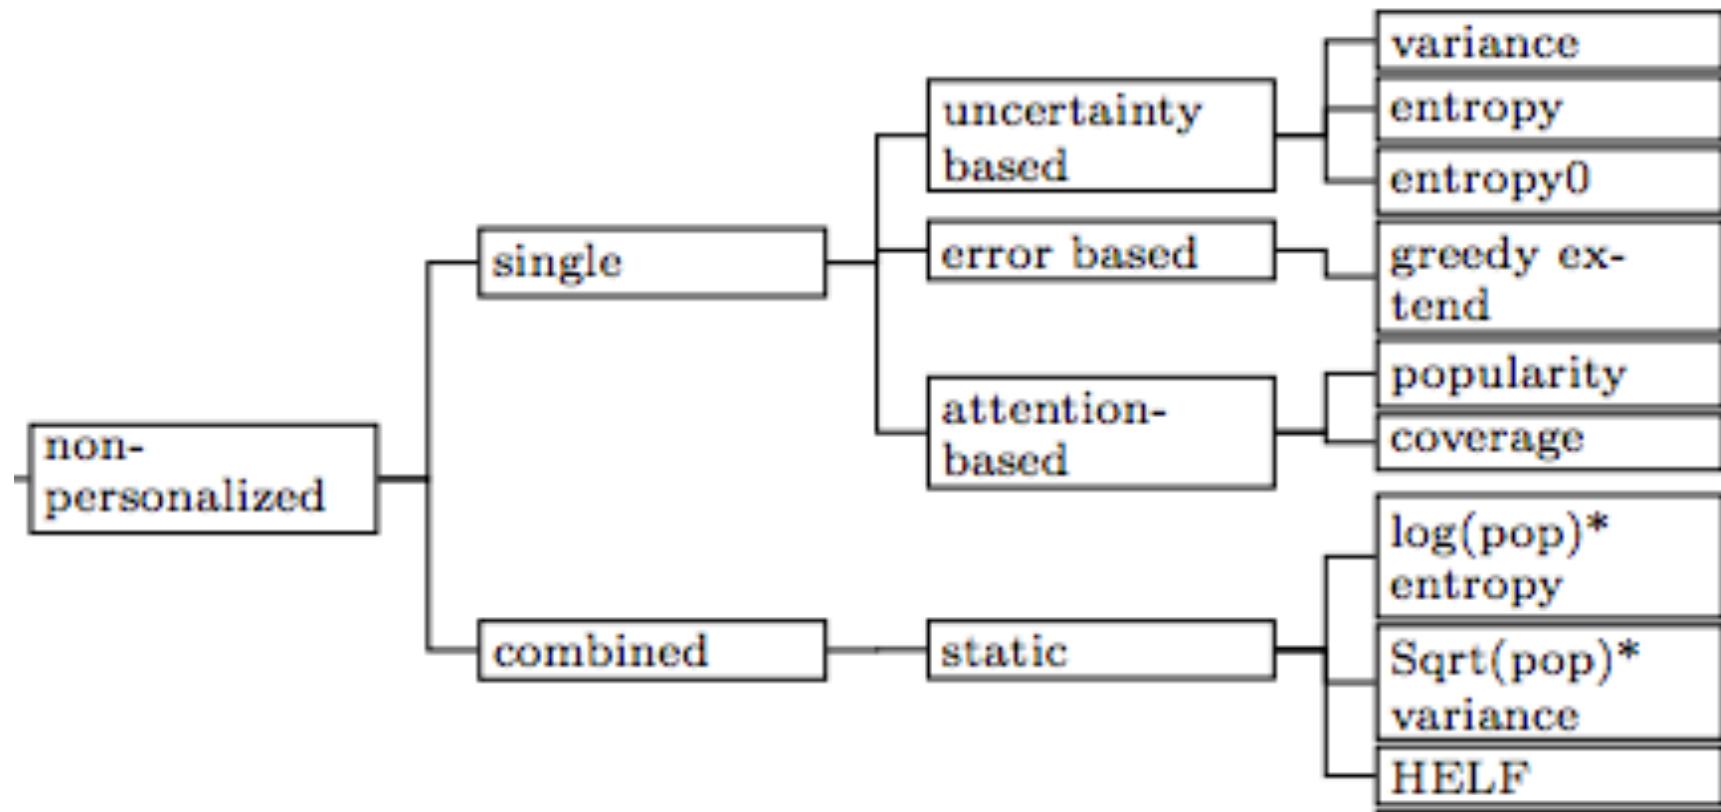
# Propiedades de los Datos

- (R1) Representado (e.g. Trilogia Star Wars, disminuir redundancia)
- (R2) Representativo (e.g. elegir items que representen tipos generales: Drama mejor que Zombie)
- (R3) Resultados: ¿Elegir este punto mejorará mi predicción o algún otro objetivo?

# Jerarquía de Estrategias



# Non-Personalized (Several Heuristics)



# Aprendizaje Activo No-Personalizado

- Estrategias de Heurística única
  - Basadas en Reducción de Incertezas
  - Basadas en Reducción del Error
  - Basadas en Atención

# Estrategias Basadas en Red. Incerteza

- Varianza

$$Variance(i) = \frac{1}{|U_i|} \sum_{u \in U_i} (r_{ui} - \bar{r}_i)^2$$

- Entropía y Entropía0

$$H = - \sum p(x) \log p(x)$$

- Entropia0 asigna el valor “0” a ratings no observados. ¿Por qué?

# Estrategias Basadas en Red. Incerteza

- Varianza: seleccionar items con alta varianza

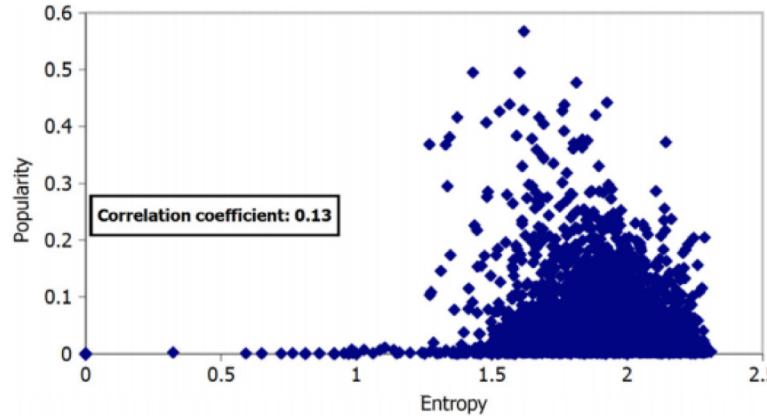
$$\text{Variance}(i) = \frac{1}{|U_i|} \sum_{u \in U_i} (r_{ui} - \bar{r}_i)^2$$

- Entropía y Entropía0

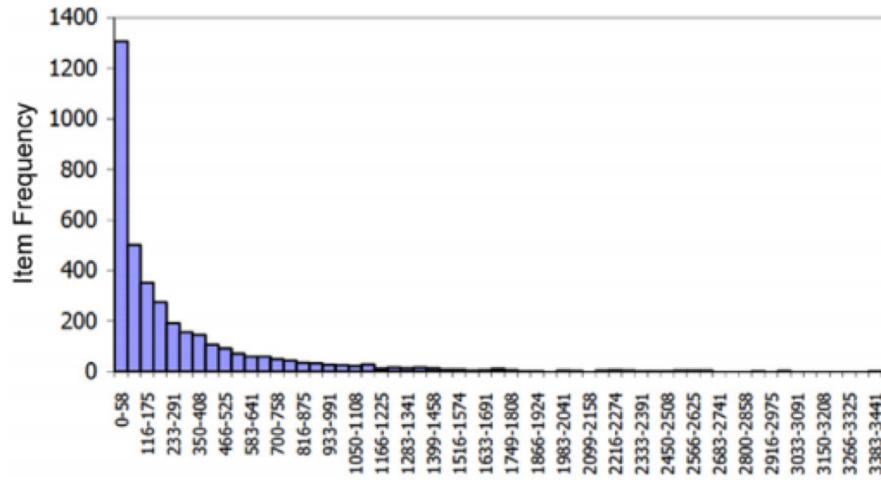
$$H = - \sum p(x) \log p(x)$$

- Entropia0 asigna el valor “0” a ratings no observados. ¿Por qué? Entropía favorece a items “oscuros” y con pocos ratings.

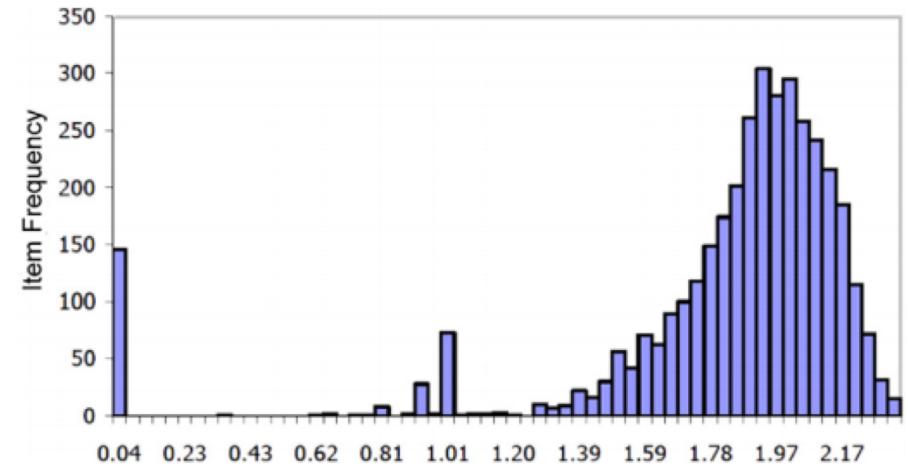
# Ratings y Entropía



**Fig. 6 – (a) Correlation between the entropy and popularity of the items (Movielens dataset) [68].**



**(a) Popularity.**



**(b) Entropy.**

**Fig. 5 – (a) Distribution of the popularity of the items, and (b) distribution of the entropy of the items (Movielens dataset) [68].**

# Estrategias Basadas en Error

- Mejorar directamente la exactitud de predicción del sistema.
- Greedy Extend (Golbandi et al. 2010): Identifica directamente el set de items que reducen el error (e.g. RMSE)

$$L_u = \operatorname{argmin}_{L \subset I_u} F(A(L))$$

- A: Algoritmo de predicción
- $F(A(L))$  : Función de error
- $I_u$  : items a los cuales “u” puede dar ratings

# Estrategias Basadas en Error

- Greedy Extend (Golbandi et al. 2010):  
Identifica directamente el set de items que reducen el error (e.g. RMSE)

$$L_u = \operatorname{argmin}_{L \subset I_u} F(A(L))$$

- El algoritmo funciona calculando RMSE antes y después de agregar el rating de un ítem.
- **Se selecciona en ítem con mayor reducción de error.**

# Estrategias Basadas en Error II

- Mejorar directamente la exactitud de predicción del sistema.
- Basadas en representatividad: Pedir al usuario que de ratings sobre ítems que pueden reconstruir mejor la matriz de ratings R

$$R \approx CX \quad \text{minimize} \ \|R - CX\|^2$$

- Donde C es un subconjunto de las columnas de R (ítems), y X es una matriz de parámetros.

# Estrategias Basadas en Atención

- Items que han recibido la mayor atención
- Fáciles de implementar, propuestas iniciales para resolver el cold-start
  - Popularidad: Elegir ítems que han recibido la mayor cantidad de ratings.
  - Co-coverage: Elegir ítems que han sido co-rated por muchos usuarios.

$$\text{Co-coverage}(i) = \sum_{j=1}^n m_{ij}$$

$m_{ij}$ : nro. de usuarios que co-rated items i y j

# Estrategias Basadas en Atención II

- Ítems que han recibido la mayor atención
- Fáciles de implementar, propuestas iniciales para resolver el cold-start
  - Popularidad: Elegir ítems que han recibido la mayor cantidad de ítems.
  - Co-coverage: Elegir ítems que han sido co-rated por muchos usuarios.
- Ambas métricas tienen el problema de **pre-fix bias**, recomendaciones irán a ítems más populares.

# Aprendizaje Activo No-Personalizado

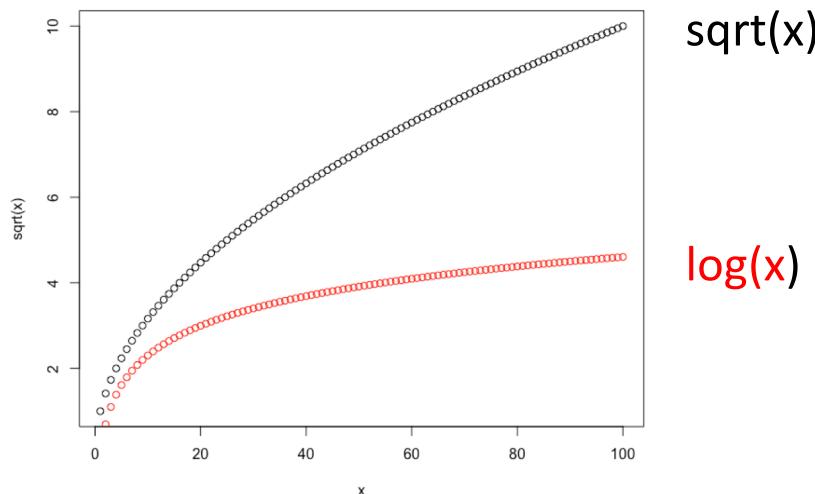
- Estrategias de Heurística Combinada (Estáticas)
  - Random Popularity
  - $\text{Log}(\text{pop}) * \text{entropy}$
  - $\text{SQRT}(\text{pop}) * \text{entropy}$
  - HELF

# Random Popularity

- Incluir elementos populares en una lista de items random, para aumentar la chance de que el usuario haya consumido el ítem y así pueda darle ratings.
- Se usó este método en estudio de movielens para eliciar ratings de usuarios nuevos en el sistema. Aspecto principal : familiaridad.
- También se le llama *Classique* a esta técnica.

# $F(\text{pop}) * \text{entropy}$

- $\text{Log}(\text{pop}) * \text{entropy}$  : Intenta combinar el efecto de popularidad con la entropía de los ratings
- $\text{Sqrt}(\text{pop}) * \text{entropy}$ : Variación usa raíz cuadrada en lugar de  $\log()$  y en algunos casos, varianza en lugar de entropía.



# HELP

- Harmonic Mean de Entropía y Logaritmo de la Frecuencia
- Combina popularidad con “informativeness”. Funciona bien porque la entropía tiende a seleccionar items que rara vez han sido “rated”.

$$HELP(i) = \frac{2 \times LF_i \times H(i)}{LF_i + H(i)}$$

# Comparación

- Basada en paper “On Bootstrapping Recommender Systems” de Golbandi et al. (2010)

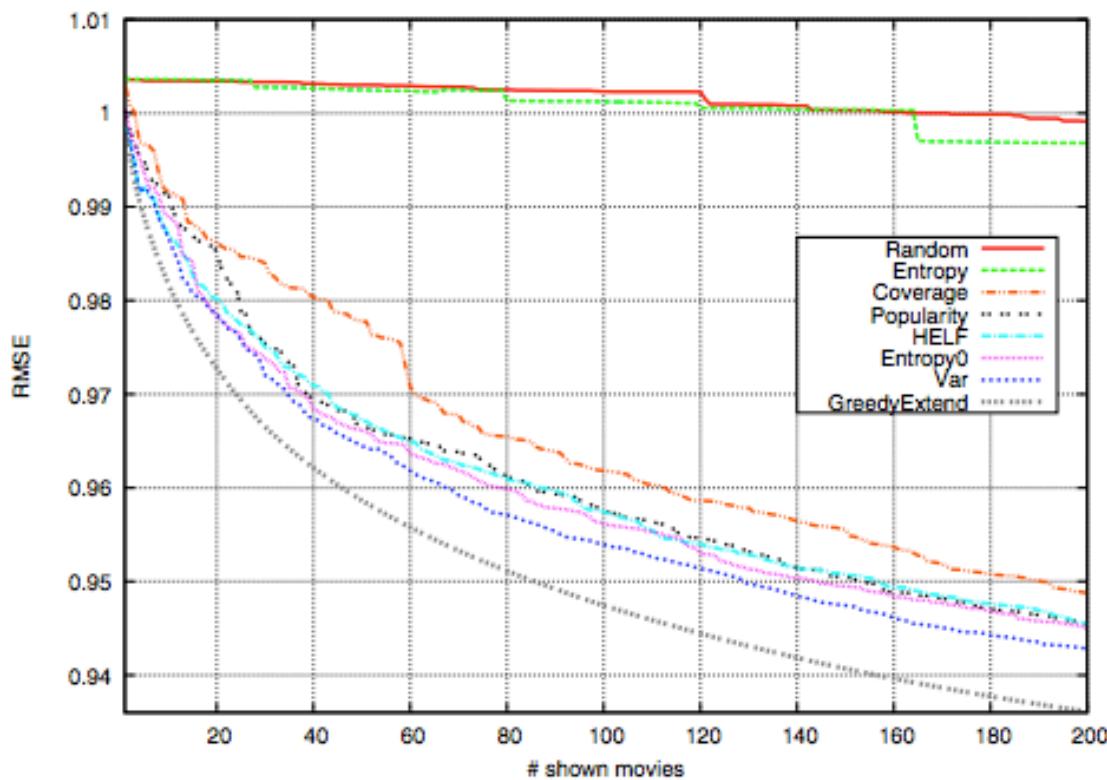


Figure 2: The test error rate vs. number of displayed items (=size of seed set), for various methods of selecting seed set items. Methods that disregard item popularity (Random and Entropy) significantly lag in performance. GreedyExtend delivers the best performing seed sets by guiding the set creation process with a suitable cost function. Note that the legend orders methods by their performance.

# Comparación

Table 1: Performance comparison of active learning strategies (“✓✓” Very Good, “✓” Good, “✗” Poor, “-” Not Available)

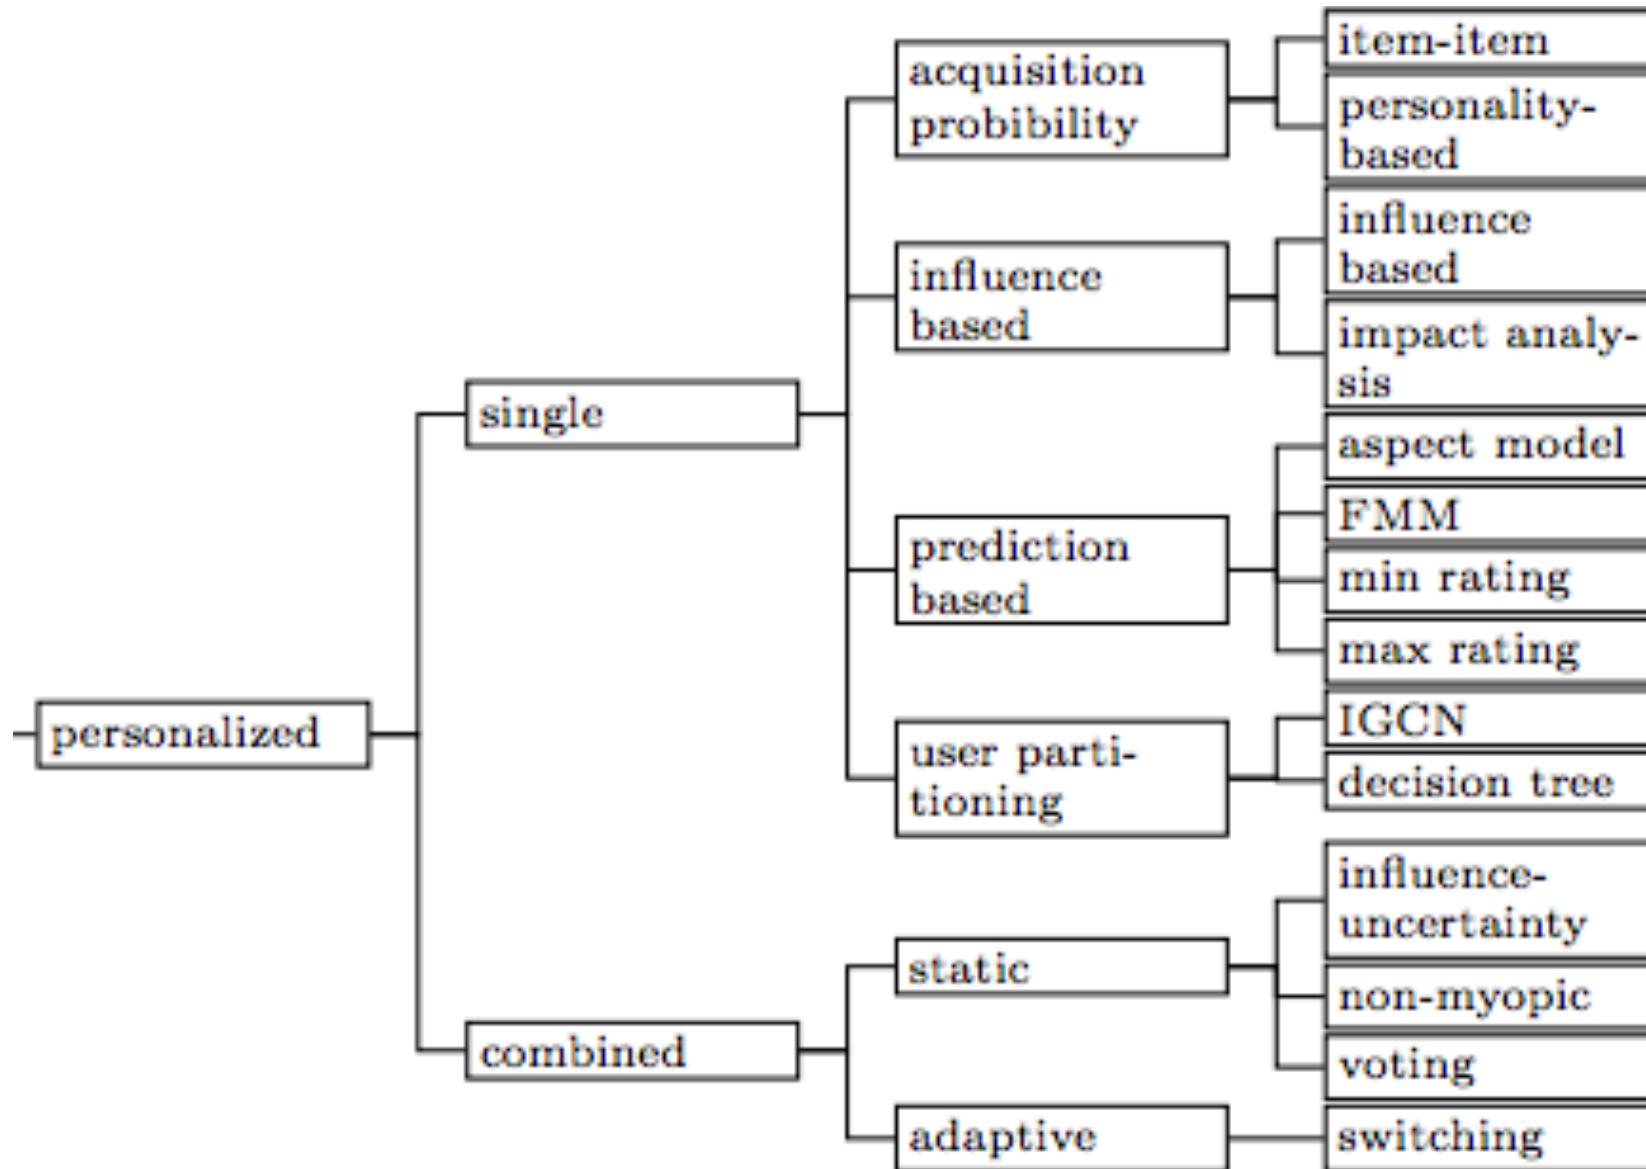
ML: Movielens, NF: Netflix, EM: EachMovie, AWM: Active Web Museum, MP: MyPersonality, STS: South Tyrol Suggests, LF: Last.fm

Type	Strategy	Metric			Eval.		Compar. Strategies	Datasets	
		MAE/RMSE	NDCG/MAP	Precision	# Rating	Online	Offline		
Non-Personalized	uncertainty based	1. variance [59, 61]	✓	-	-	-	✗	2, 4, 6, 9, 24	AWM, EM
		2. entropy [20, 67]	✗	-	-	-	✗	3, 6, 8, 9, 11, 13, 22	EM
		3. entropy0 [67]	✓✓	-	-	✓✓	✗	2, 6, 8, 11, 13, 22	ML
	error reduction	4. greedy extend [68]	✓	-	-	-	✗	2, 3, 6, 7, 10, 11	NF
		5. representative [69]	-	✓✓	✓✓	-	✗	6	NF, ML, LF
	attention based	6. popularity [20, 67]	✓	-	-	✓✓	✗	2, 8, 9, 11, 13, 22	ML
		7. co-coverage [68]	✗	-	-	-	✗	2, 3, 4, 6, 10, 11	NF
	Combined	8. rand-pop [20, 67]	✗	-	-	✗	✗	2, 3, 6, 11, 13, 22	ML
		9. log(pop)*entropy [20]	✓✓	-	-	✓	✗	3, 6, 8, 13	ML
		10. sqrt(pop)*var [68]	✓	-	-	-	✗	2, 3, 4, 6, 7, 11	NF
		11. HELF [67]	✓✓	-	-	✗	✗	2, 3, 6, 8, 13, 22	ML
		12. non-pers-part rand. [11]	✓	✓✓	✓	✗	-	1, 6, 9, 12, 14, 20, 21, 28, 29	ML, NF

# Aprendizaje Activo Personalizado

- Estrategias de Heurística única
  - Probabilidad de Adquisición
  - Basadas en Impacto
  - Basadas en Predicción
  - Particionamiento de los Usuarios

# Personalized (Several Heuristics)



# Probabilidad de Adquisición

- Estrategia Item-Item: Seleccionar ítems más similares a los ítems que el usuario ya evaluó

$$\text{sim}(i, j) = \frac{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_i)(r_{uj} - \bar{r}_j)}{\sqrt{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_i)^2} \sqrt{\sum_{u \in U_{ij}} (r_{uj} - \bar{r}_j)^2}}$$

- Predicción Binaria: Intenta identificar los ítems que el usuario más probablemente hubiese consumido/evaluado. Transforma matriz de ratings en 1/0 y se predice un score para los ítems con  $r_{ui} = 0$ .

# Probabilidad de Adquisición

- Predicción Binaria basada en personalidad:  
Intenta identificar los items que el usuario más probablemente hubiese consumido/evaluado, considera características del usuario como Personalidad.

$$\hat{s}_{ui} = \bar{i} + b_u + q_i^\top \left( p_u + \sum_{a \in A(u)} y_a \right)$$

# Basadas en Impacto

- Seleccionan ítems con la intención de minimizar la incertezza de predicción para todos los ítems, no necesariamente el error final.
  - Basada Directamente en Influencia: Calculamos  $r_{ui}$  y  $r_{ui}' = r_{ui} - 1$ , observamos el impacto en la predicción de otros ítems usando ambos.
  - Análisis de Impacto: Basado en análisis del grafo bipartito

# Basadas en Impacto II

- Análisis de Impacto: Basado en análisis del grafo bipartito. Busca qué ratings (enlaces) pueden producir más “four-node paths”

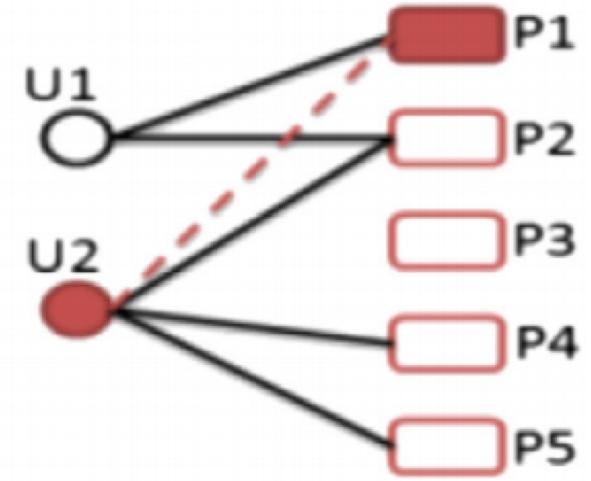
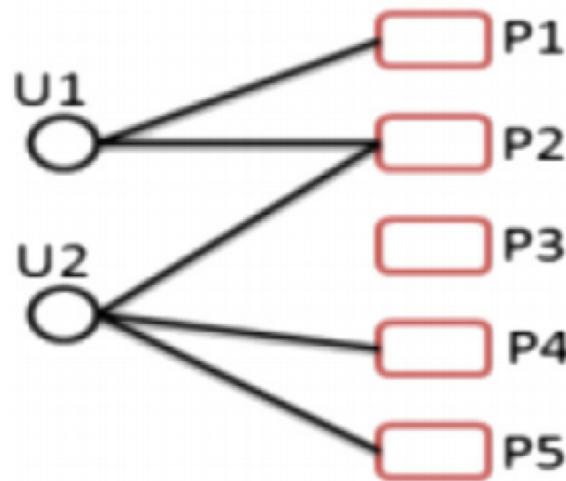


Fig. 7 – Simple Bipartite Graph Model for CF [75].

# Basada en Predicción

- Se predicen ítems con modelos tradicionales, los ítems predichos con mayor rating se presentan a los usuarios:
  - Modelo de Aspecto: relacionado con topic models o “aspectos”

$$p(r|u, i) = \sum_{z \in Z} p(r|z, i)p(z|u)$$

- Highest Predicted / Lowest Predicted
- MinNorm: Hacer factorización matricial y elegir los ítems con menor norma en sus vectores latentes.

# Particionamiento de los Usuarios

- IGCN: Information Gain a través de clustering de los vecinos. Consiste en construir un árbol de decisión donde los nodos son ítems y las hojas son clusters de usuarios.
- Árbol de Decisión: Similar al anterior, pero más específico. Dado un ítem o grupo de ítems, se separan 3 grupos: *Lovers*, *Haters* y *Unknowns*. Se hacen predicciones para cada grupo, sobre los ítems no evaluados aún.

# Aprendizaje Activo Personalizado

- Estrategias de Heurística Combinada
  - Combinación Estática
    - Influencia-Incerteza
    - No miópica
    - Decision Tree-MF
    - Functional MF
    - Votación
  - Adaptativas
    - Switiching

# Influencia-Incerteza

- Combina 2 estrategias: influencia y varianza

$$\operatorname{argmax}_i \text{Var}(i) I(i)$$

- Donde  $I(i)$  es la influencia del ítem  $i$  sobre el resto del dataset.

# No miótica

- Combina 2 estrategias: minRated y minNorm

$$\text{score}(i) = (1 - w) \text{minRating\_rank}(i) + w \text{minNorm\_rank}(i)$$

$$w = \frac{\#\text{current\_request} - 1}{\#\text{total\_request}}$$

- Donde `#current_request` es el número de veces que el usuario ha sido solicitado por rating, y `#total_request` el total esperado.

# Comparación

Table 1: Performance comparison of active learning strategies (“✓✓” Very Good, “✓” Good, “✗” Poor, “-” Not Available)

ML: MovieLens, NF: Netflix, EM: EachMovie, AWM: Active Web Museum, MP: MyPersonality, STS: South Tyrol Suggests, LF: Last.fm

	Type	Strategy	Metric				Eval.		Compar. Strategies	Datasets
			MAE/RMSE	NDCG/MAP	Precision	# Rating	Online	Offline		
Personalized	acquisition prob.	13. item-item [20, 67]	✗	-	-	✓✓	✗	✗	2, 3, 6, 8, 9, 11, 22	ML
		14. binary-pred [11, 12]	✓	✗	✓✓	✓	-	✗	1, 6, 9, 12, 20, 21, 28, 29	ML, NF
		15. personality-based [70, 97]	✓✓	✓✓	-	✓✓	✗	✗	3, 9, 14	STS, MP
	prediction based	16. impact analysis [71]	✓✓	-	-	-	-	✗	9	ML
		17. aspect model [72, 73]	✓	-	-	-	-	✗	2	EM, ML
		18. min rating [74]	✓	-	-	-	-	✗	19,25	ML
		19. min norm [74]	✗	-	-	-	-	✗	18,25	ML
		20. highest-pred [11, 12]	✓	✗	✓✓	✓	-	✗	1, 6, 9, 12, 14, 21, 28, 29	ML, NF
		21. lowest-pred [11, 12]	✓	✗	✓	✗	-	✗	1, 6, 9, 12, 14, 20, 28, 29	ML, NF
	user partitioning	22. IGCN [67]	✓✓	-	-	✓	✗	✗	2, 3, 6, 8, 11, 13	ML
		23. decision tree [64]	✓✓	-	-	-	-	✗	3, 4, 10, 11	NF
Combined	static combin.	24. influence based [61]	✓✓	-	-	-	-	✗	1, 4, 6, 9	ML
		25. non-myopic [74]	✓	-	-	-	-	✗	18, 19	ML
		26. treeU [75]	✓	-	-	-	-	✗	23, 27	ML, EM, NF
		27. fMF [75]	✓✓	-	-	-	-	✗	23, 26	ML, EM, NF
		28. pers-partially rand. [11]	✓	✓✓	✓	✗	-	✗	1, 6, 9, 12, 14, 20, 21, 28, 29	ML, NF
		29. voting [11, 12]	✓✓	✓✓	✗	✗	-	✗	1, 6, 9, 12, 14, 20, 21, 28	ML, NF
		30. switching [76]	✓✓	✓✓	-	✓✓	-	✗	9, 20, 29	ML

# Resumen

**Table 1 – Performance comparison of active learning strategies (“✓✓” Very Good, “✓” Good, “✗” Poor, “–” Not Available) ML: MovieLens, NF: Netflix, EM: EachMovie, AWM: Active Web Museum, MP: MyPersonality, STS: South Tyrol Suggests, LF: Last.fm.**

	Type	Strategy	Metric				Eval.		Compar. Strategies	Datasets	
			MAE/ RMSE	NDCG/ MAP	Precision	# Rating	Online	Offline			
Non-personalized	Single	Uncertainty based	1. Variance [59,61] 2. Entropy [20,68] 3. Entropy0 [68]	✓ ✗ ✓✓	– – –	– – ✓✓	– – y	y y y	2, 4, 6, 9, 24 3, 6, 8, 9, 11, 13, 22 2, 6, 8, 11, 13, 22	AWM, EM EM ML	
		Error reduction	4. Greedy extend [69] 5. Representative [70]	✓ –	– ✓✓	– ✓✓	– –	y y	2, 3, 6, 7, 10, 11 6	NF NF, ML, LF	
		Attention based	6. Popularity [20,68] 7. Co-coverage [69]	✓ ✗	– –	– –	✓✓ –	y –	2, 8, 9, 11, 13, 22 2, 3, 4, 6, 10, 11	ML NF	
	Combined	Static combin.	8. Rand-pop [20,68] 9. Log(pop)*entropy [20] 10. sqrt(pop)*var [69] 11. HELF [68]	✗ ✓✓ ✓ ✓✓	– – – –	– ✓ – ×	y y – y	y y y y	2, 3, 6, 11, 13, 22 3, 6, 8, 13 2, 3, 4, 6, 7, 11 2, 3, 6, 8, 13, 22	ML ML NF ML	
			12. Non-pers-part rand. [11]	✓	✓✓	✓	×	–	y	1, 6, 9, 12, 14, 20, 21, 28, 29	
			13. Item-item [20,68] 14. Binary-pred [11,12] 15. Personality-based [77,97] 16. Impact analysis [75]	✗ ✓ ✓✓ ✓✓	– × ✓✓ –	– ✓✓ – –	✓✓ ✓ ✓✓ –	y – y –	y y y y	2, 3, 6, 8, 9, 11, 22 1, 6, 9, 12, 20, 21, 28, 29 3, 9, 14 9	ML ML, NF STS, MP ML
			17. Aspect model [83,84] 18. Min rating [76] 19. Min norm [76] 20. Highest-pred [11,12] 21. Lowest-pred [11,12]	✓ ✓ ✗ ✓ ✓	– – – × ×	– – – ✓✓ ✓	– – – ✓ ×	y y y – –	2 19,25 18,25 1, 6, 9, 12, 14, 21, 28, 29 1, 6, 9, 12, 14, 20, 28, 29	EM, ML ML ML ML, NF ML, NF	
Personalized	Single	Prediction based	22. IGCN [68] 23. Decision tree [64]	✓✓ ✓✓	– –	– –	✓ –	y –	y y	2, 3, 6, 8, 11, 13 3, 4, 10, 11	
			24. Influence based [61] 25. Non-myopic [76]	✓✓ ✓	– –	– –	– –	– –	y y	1, 4, 6, 9 18, 19	
			26. TreeU [90] 27. fMF [90]	✓ ✓✓	– –	– –	– –	– –	y y	23, 27 23, 26	
			28. Pers-partially rand. [11]	✓	✓✓	✓	×	–	y	1, 6, 9, 12, 14, 20, 21, 28, 29	
			29. Voting [11,12] 30. Switching [91]	✓✓ ✓✓	✓✓	×	×	–	y	1, 6, 9, 12, 14, 20, 21, 28 9, 20, 29	
	Combined	Adaptive combin.	30. Switching [91]	✓✓	✓✓	–	✓✓	–	y	ML	

# Evaluacion Offline

- Tres pasos:
  - Developing the candidate active learning strategies and conducting preliminary studies (e.g. reviewing the literature, forming a hypothesis).
  - Conducting offline experiments on the existing rating dataset to discover and select the most promising strategies.
  - Conducting online experiments with real users to remove any possible bias introduced by the nature of offline experiments, and ultimately to verify the effectiveness of the selected strategies.

# Evaluacion Online

- Adquisición de ratings natural vs. controlada
- System vs. user-centered evaluation

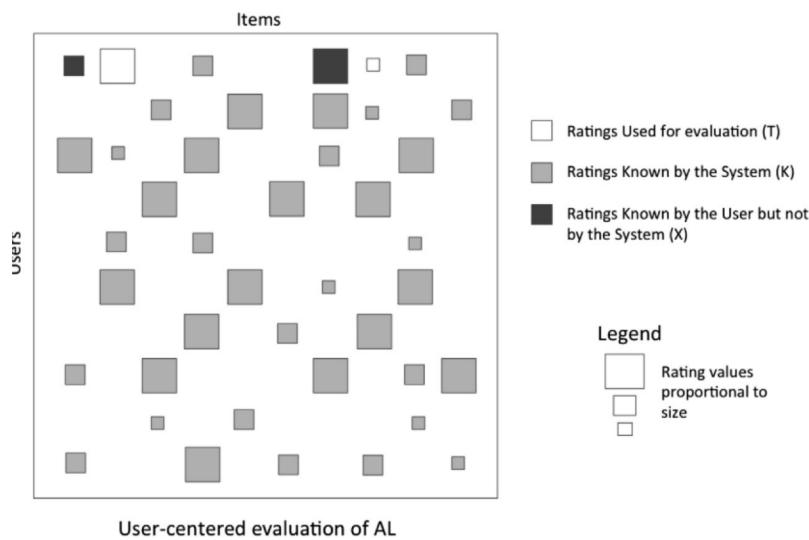


Fig. 8 – User-centred evaluation of active learning strategies [11].

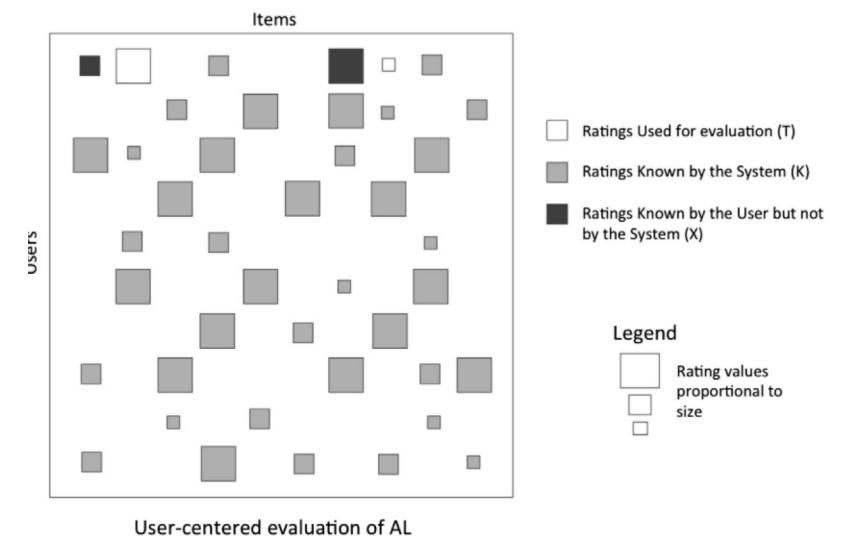


Fig. 8 – User-centred evaluation of active learning strategies [11].

# Resumen

- Elicitar sólo items con ratings altos produce sesgo en el modelo y las predicciones
- Aleatorización parcial puede ser beneficiosa
- Personalización incrementa la chance de que los usuarios provean ratings
- Explotar información adicional (personalidad, información de la red) puede también ser beneficioso