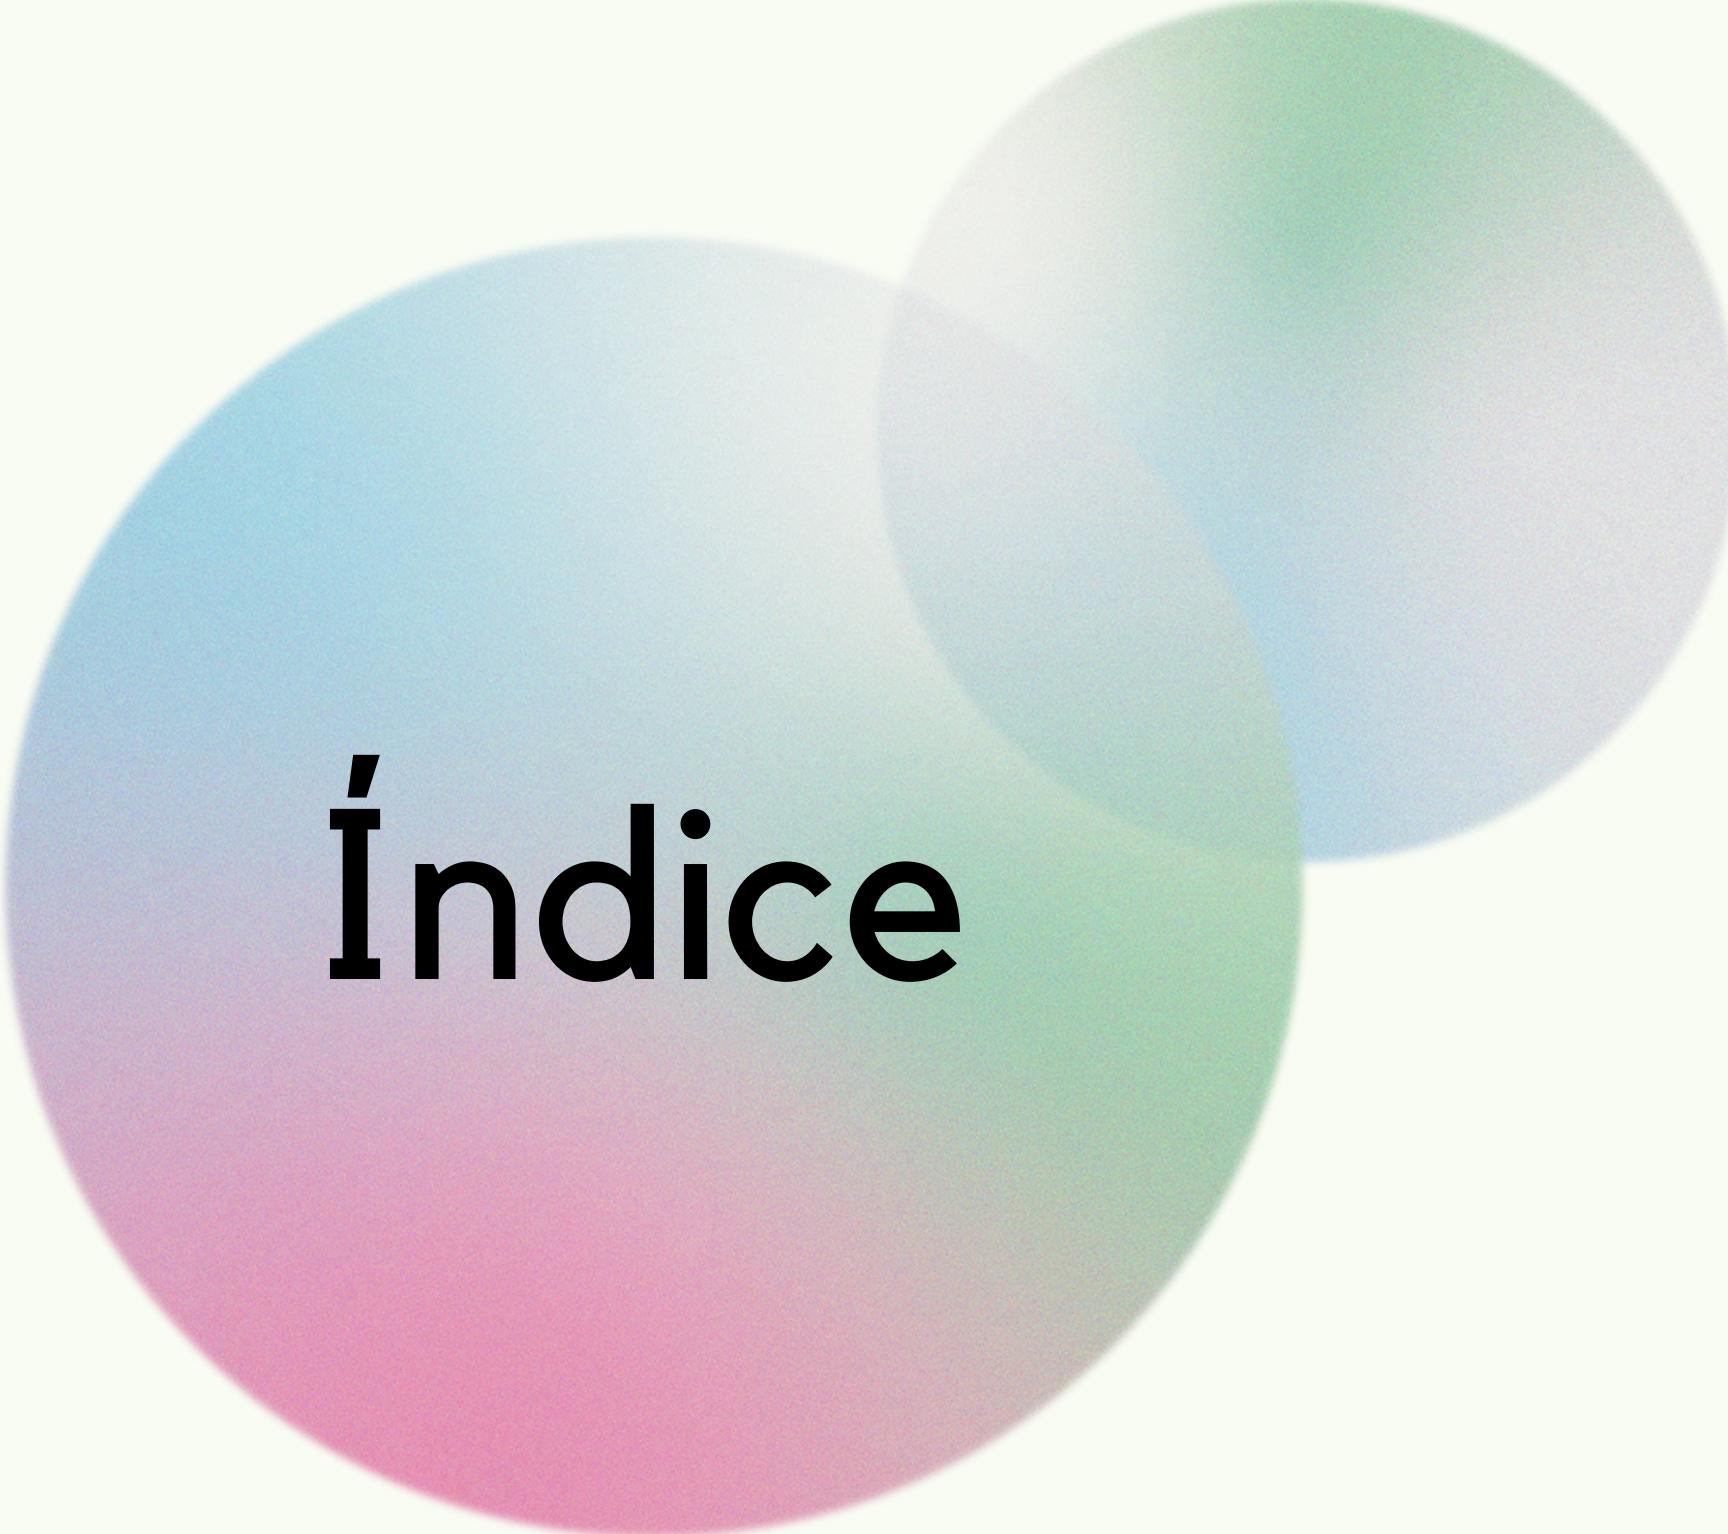


Identifying New Podcasts with High Appeal Using Pure Exploration Infinitely-Armed Bandit Strategy

Aziz et al. (2022)

Camila Denecken
Ignacio Díaz
Sofía Escobedo
Rafaela Kara

IIC3633 - Sistemas Recomendadores



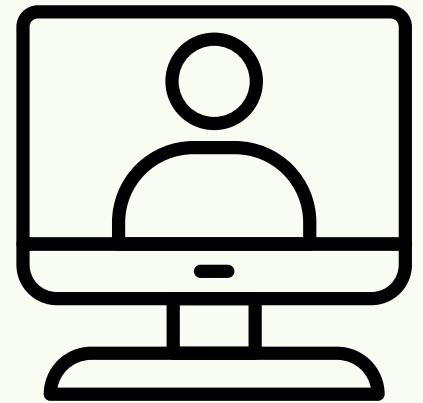
Índice

- Problema
- ¿Por qué es importante?
- Estado del arte
- Estudios preliminares
- Propuesta
- Resultados
- Conclusión

**¿Cómo podemos
identificar el
contenido más
prometedor para una
plataforma de
recomendaciones?**

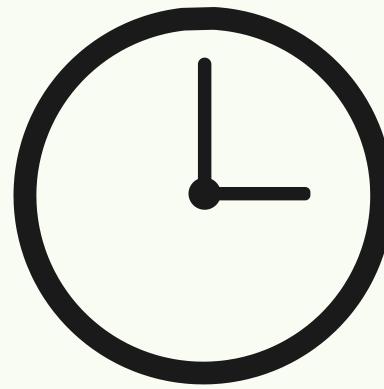
EL PROBLEMA

El problema



Creciente Diversidad de Contenido en Línea

Diversidad de creadores de contenido en línea, innovación constante en forma y contenido.



Importancia de la Identificación Temprana

Identificar los podcasts recientes más atractivos para destacarlos y apoyar a los creadores en las primeras etapas.



Rol de Algoritmos de Bandas

Métodos eficientes en la evaluación y selección de contenido en entornos con varias cantidades de opciones

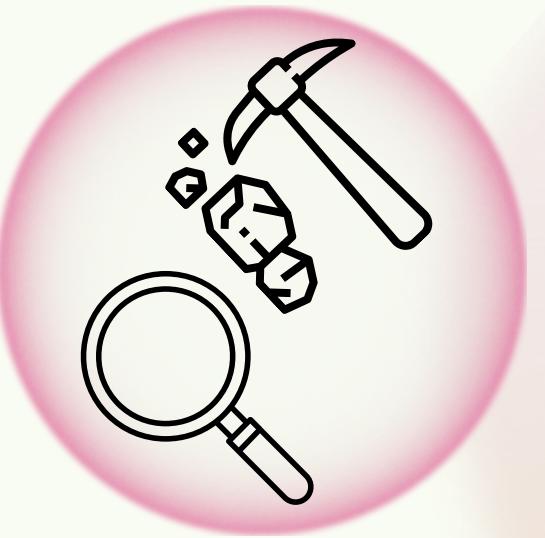
¿POR QUÉ ES IMPORTANTE?

- 01** Mejora en la experiencia de usuarios y creadores.
- 02** Apoyo a la innovación
- 03** Ampliación a Otros Tipos de Contenido

Estado del arte



Exploración Pura



Exploración vs
Explotación

Explotación vs Exploración

Minimizar el arrepentimiento acumulado

CBT

Two Target

Empirical CBT

Explotación Pura

Arrepentimiento simple, presupuesto fijo y confianza fija

Chernoff

SIRI

Successive
Rejects

Hyperband

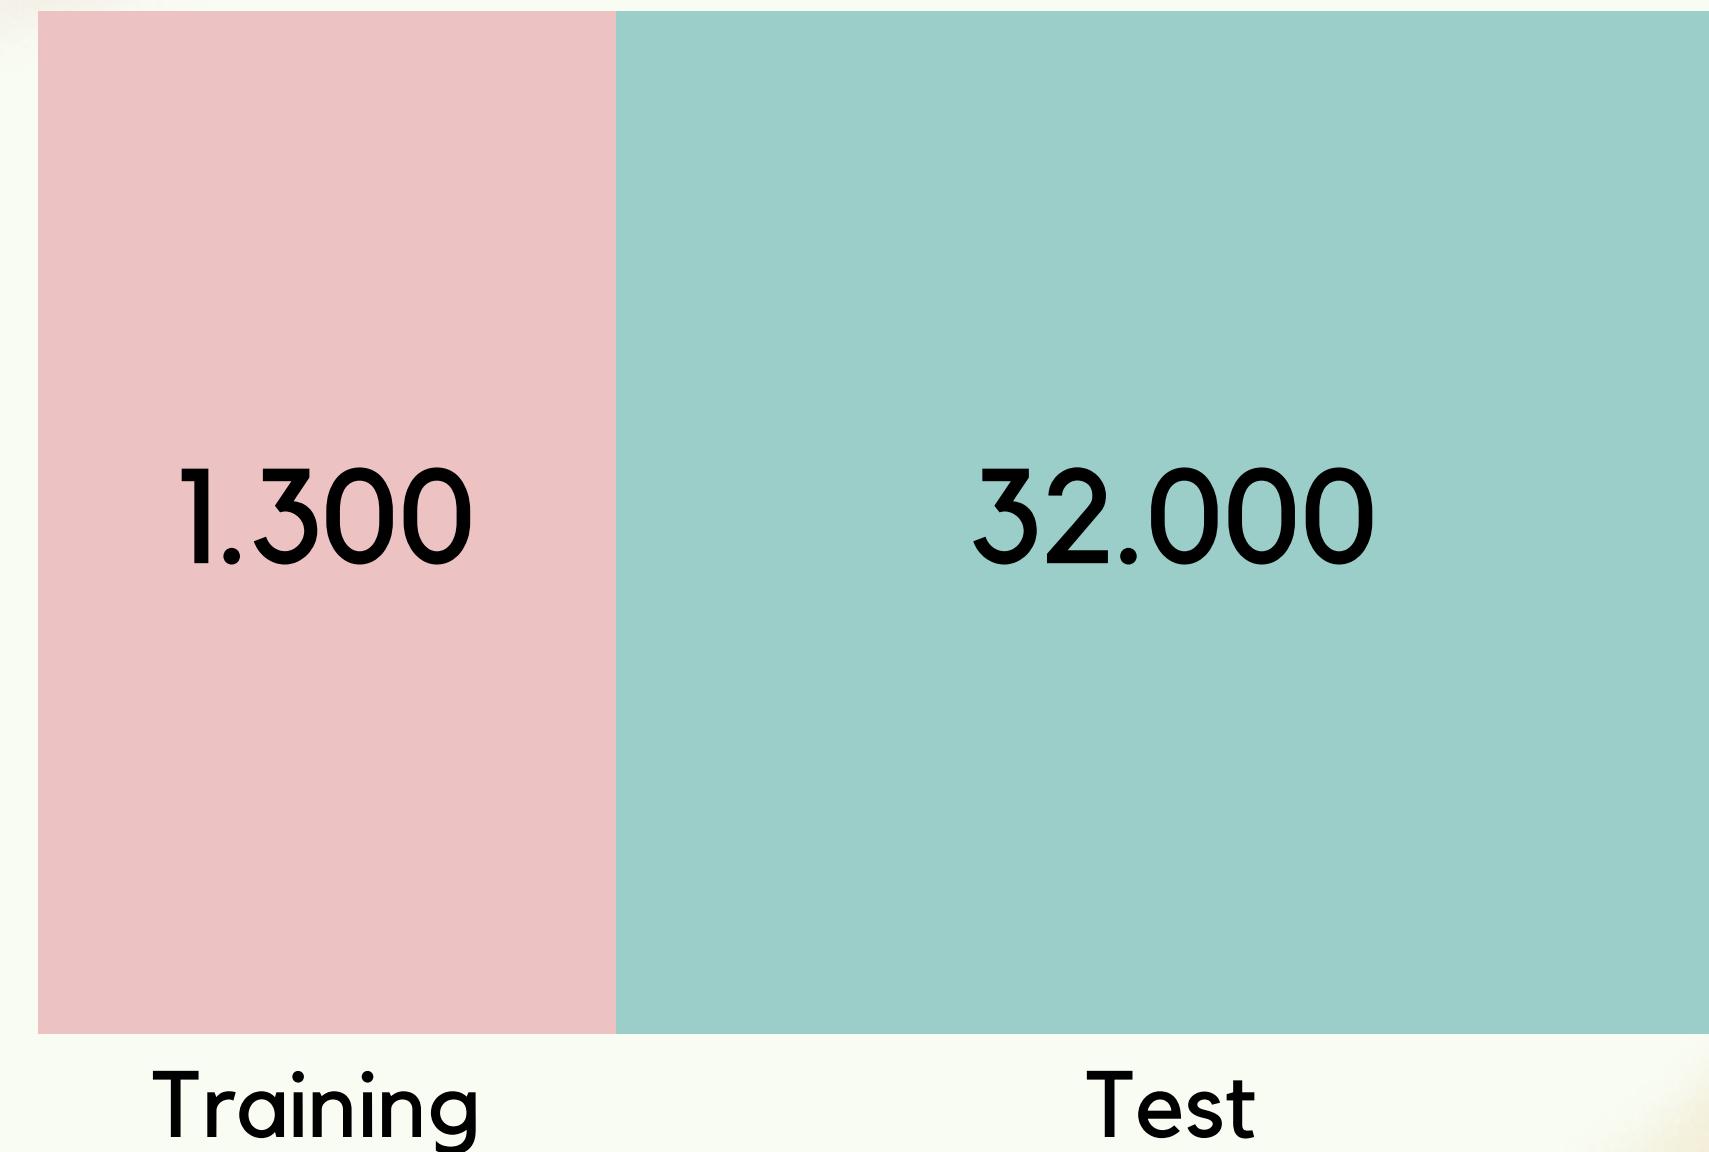
Estudio de motivación

Predicción de
popularidad
futura

VS

Identificar
atractivo
general

Estudio de motivación



Estudio de motivación

- Streams acumulados
- Horas consumidas
- Total de seguidores
- Total de oyentes

Consumo

- Temática
- Episodios totales
- Descripción
- Duración

Contenido

Estudio de motivación



Acumulación de *streams* entre 60 y 90 días del lanzamiento.

Lasso, Linear Regression, AdaBoost, RandomForest.

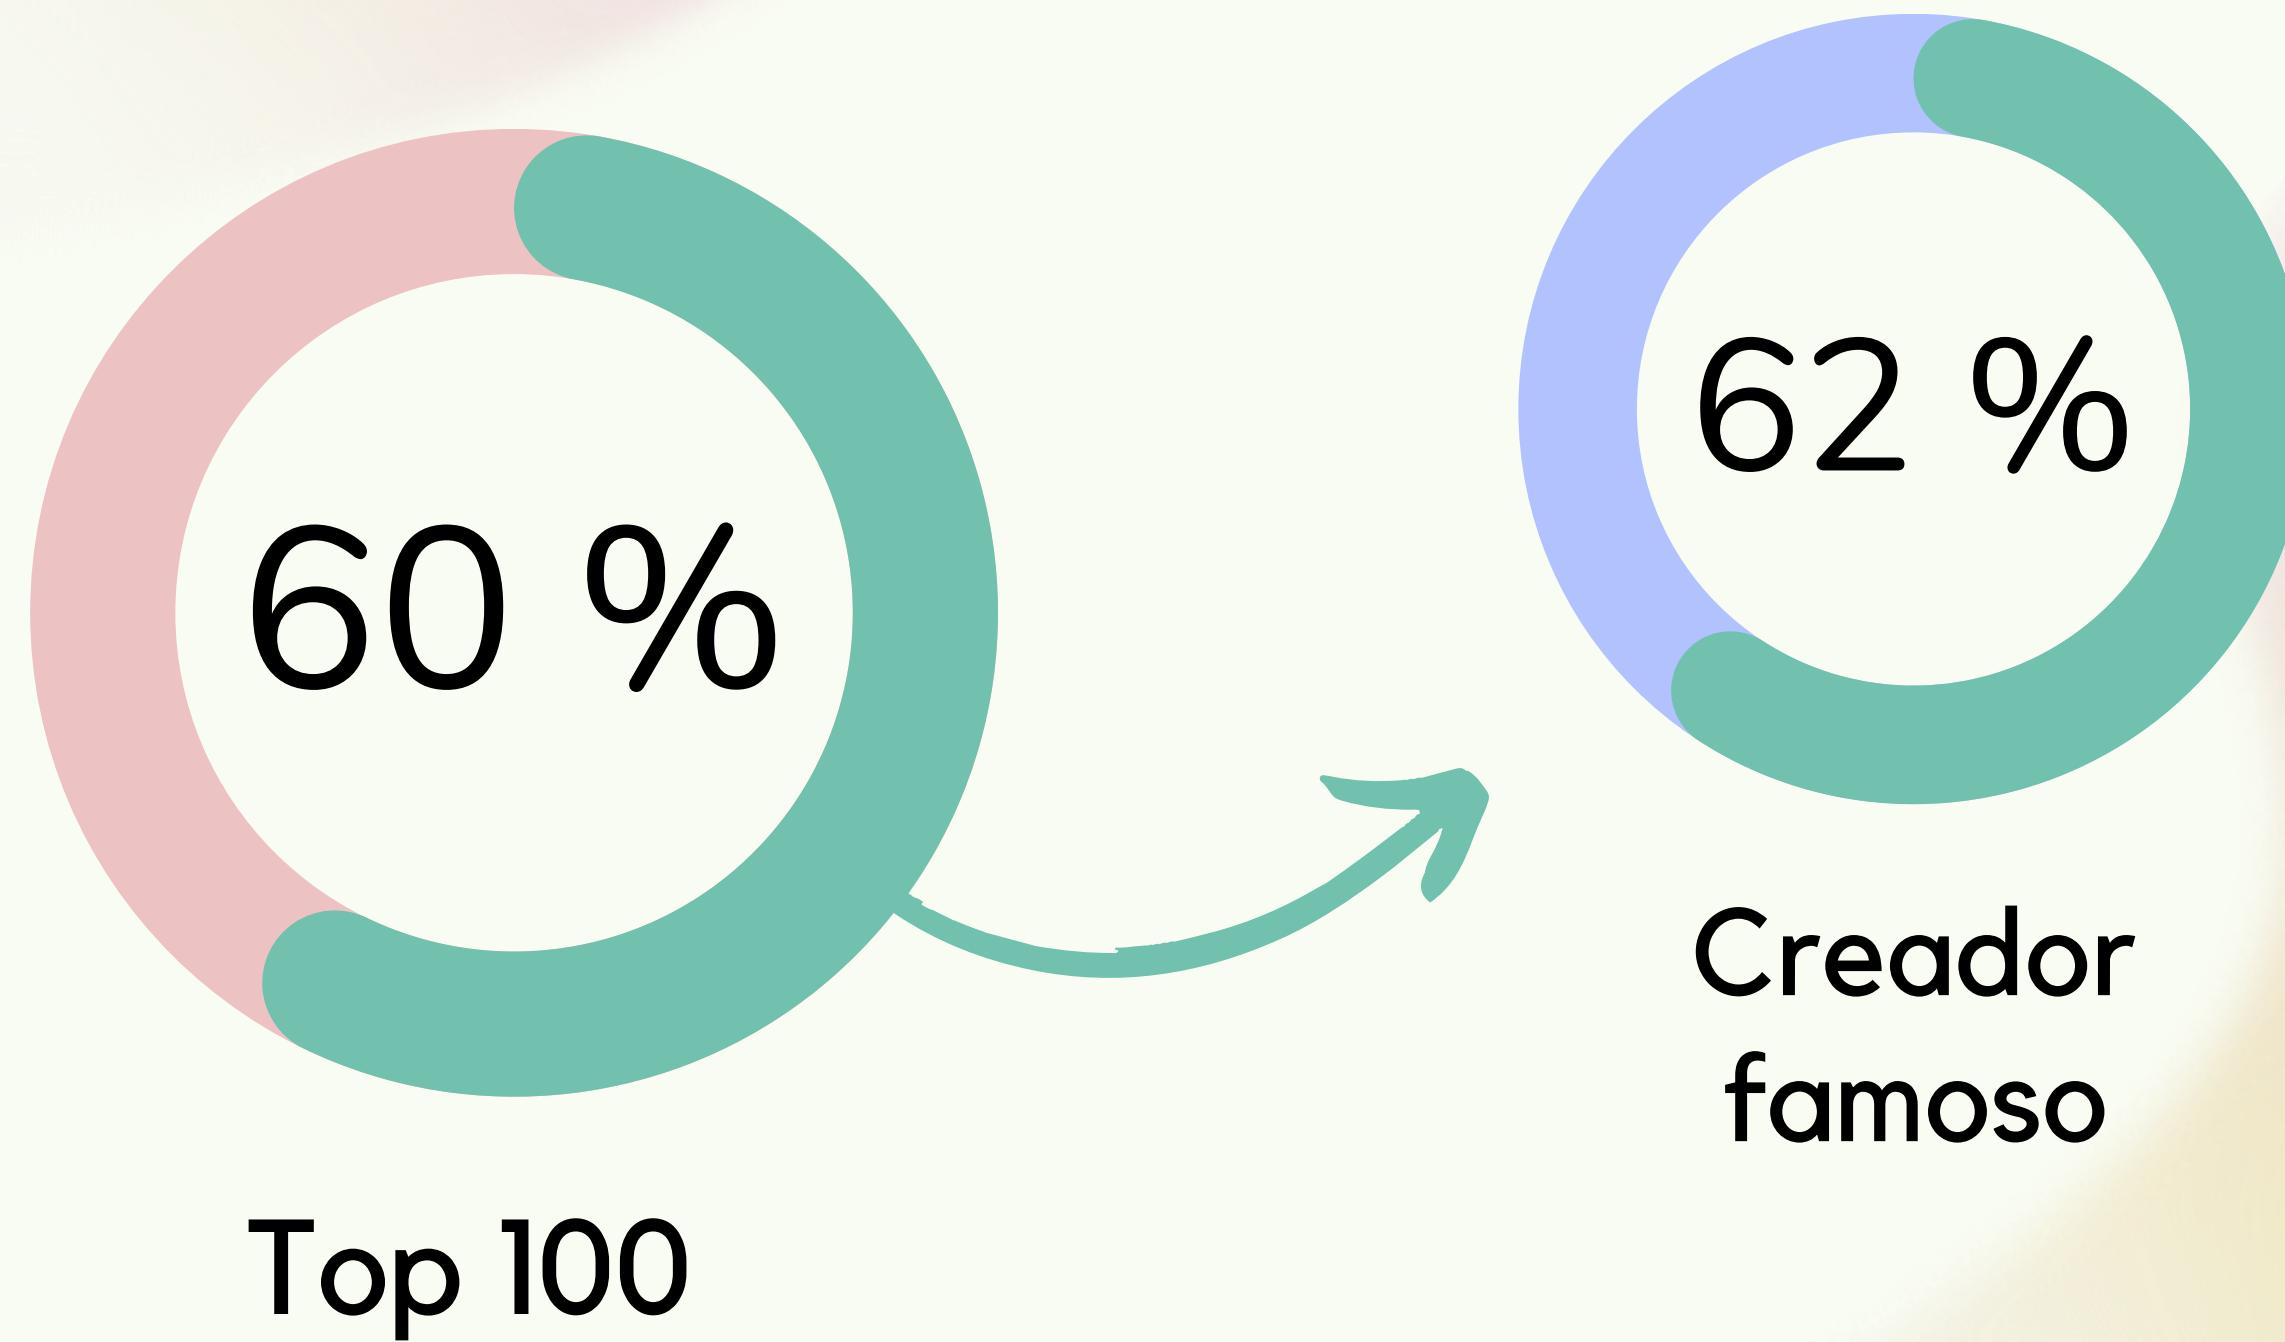


Baseline SortByPopularity, ranking streams después de 30 días.

Estudio de motivación

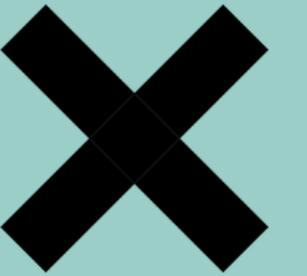
	Podcast launch day								
	Consumption			Content			Consumption+content		
Model	k=50	k=100	k=150	k=50	k=100	k=150	k=50	k=100	k=150
LinearReg.	0.220	0.180	0.127	0.020	0.010	0.007	0.220	0.170	0.147
Lasso	0.280	0.200	0.167	0.020	0.010	0.007	0.260	0.160	0.120
AdaBoost	0.180	0.090	0.060	0.000	0.000	0.013	0.080	0.080	0.060
RandomForest	0.200	0.100	0.073	0.000	0.000	0.007	0.160	0.090	0.060
SortByPopularity	0.360*	0.240*	0.180*	—	—	—	—	—	—
	30 days after podcast launch								
LinearReg.	0.860	0.720	0.607	0.080	0.050	0.033	0.640	0.530	0.393
Lasso	0.860	0.720	0.607	0.080	0.040	0.033	0.660	0.530	0.393
AdaBoost	0.400	0.400	0.427	0.000	0.020	0.013	0.800	0.660	0.573
RandomForest	0.640	0.580	0.500	0.020	0.020	0.027	0.800	0.640	0.513
SortByPopularity	0.880*	0.740*	0.613*	—	—	—	—	—	—
	60 days after podcast launch								
LinearReg.	0.820	0.890	0.813	0.140	0.090	0.073	0.820	0.840	0.767
Lasso	0.820	0.890	0.813	0.140	0.090	0.073	0.820	0.840	0.787
AdaBoost	0.960	0.900	0.713	0.040	0.020	0.020	0.960	0.900	0.707
RandomForest	0.940	0.770	0.733	0.060	0.040	0.040	0.860	0.810	0.767
SortByPopularity	0.900	0.880	0.813*	—	—	—	—	—	—

Estudio de motivación



Estudio de atractivo general al azar

700

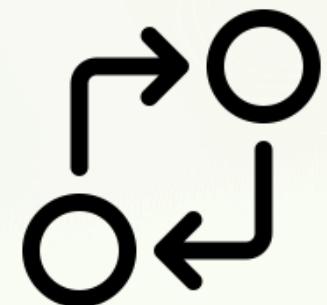


Podcasts

Esconder
datos

Misma
posición

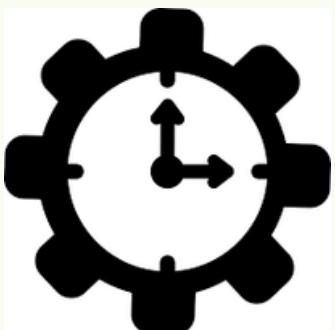
Estudio de atractivo general al azar



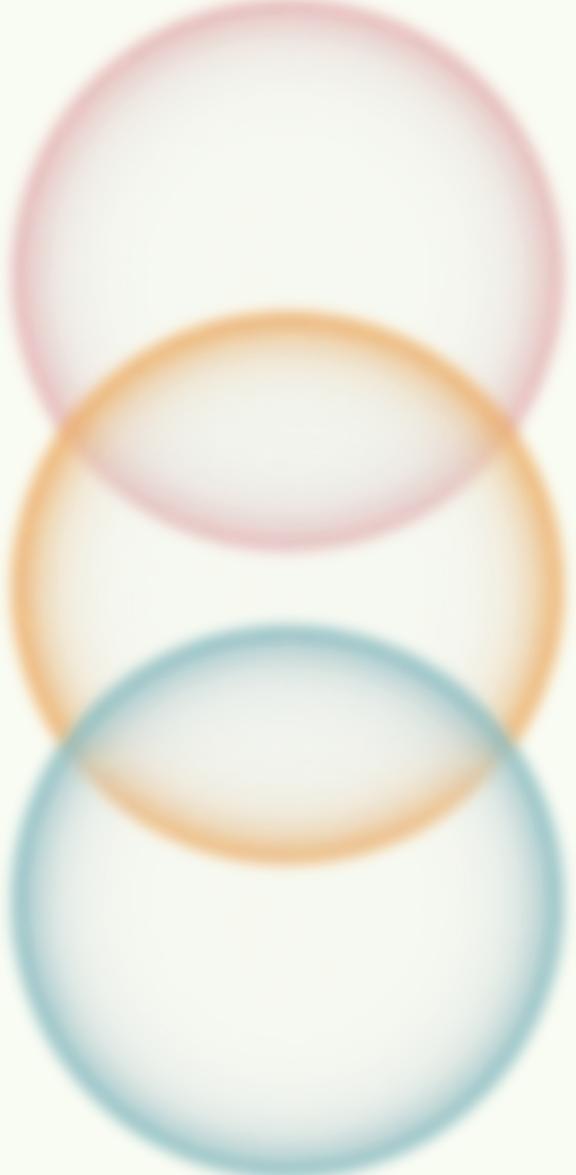
Streams acumulados en distintos puntos de vida no correlacionados con atractivo general.



No es factible realizar este método con todos los podcasts.



Modelo de bandas más eficiente para este experimento.



ISHA: Successive Halving for Infinite- Armed Bandits

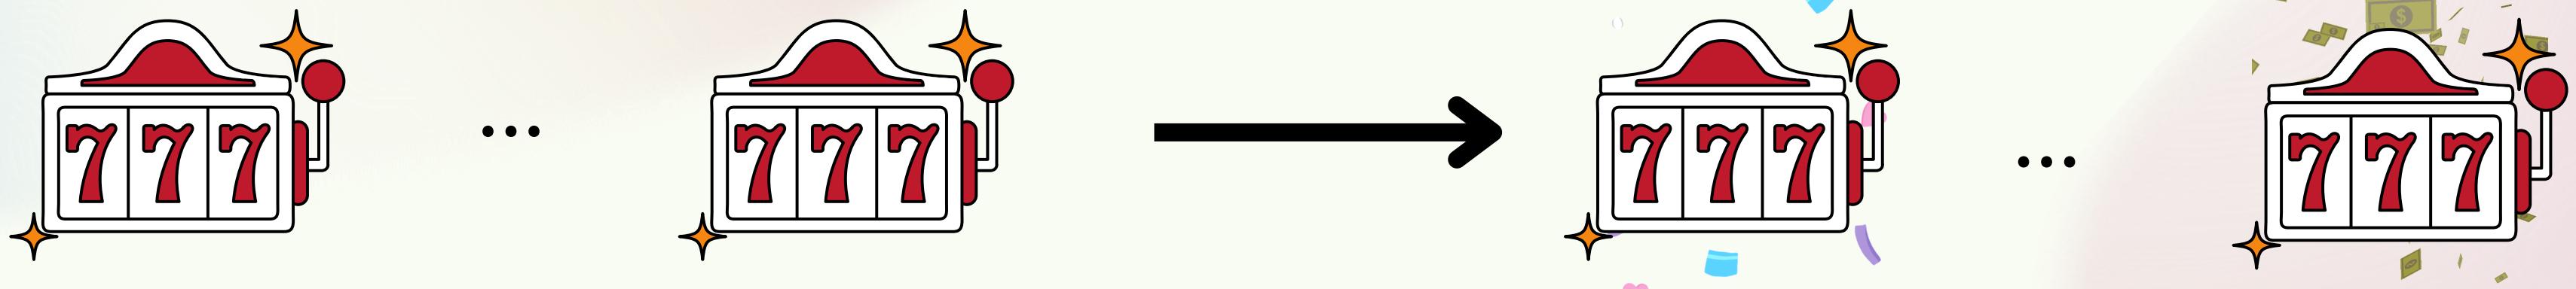
ISHA



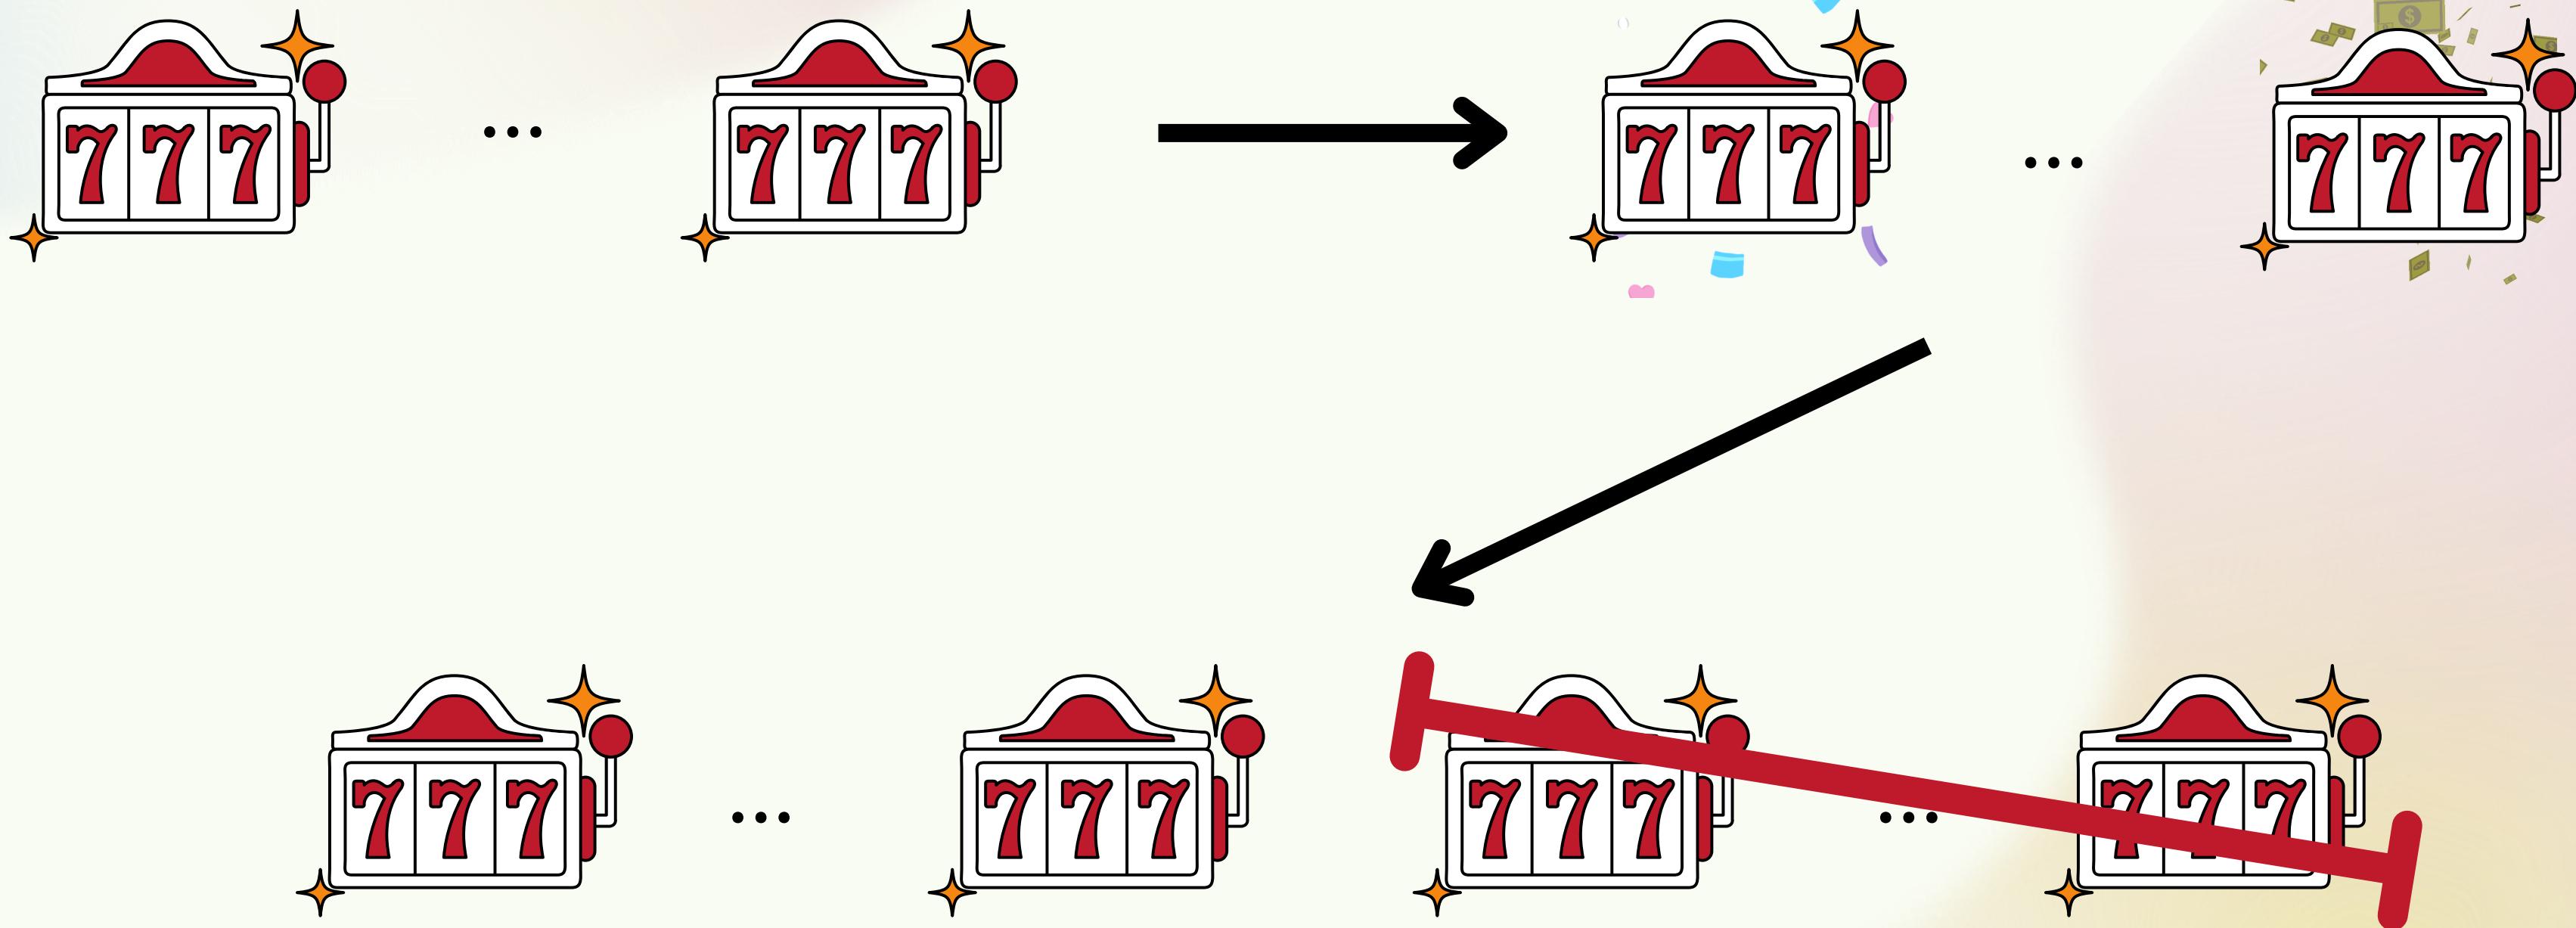
...



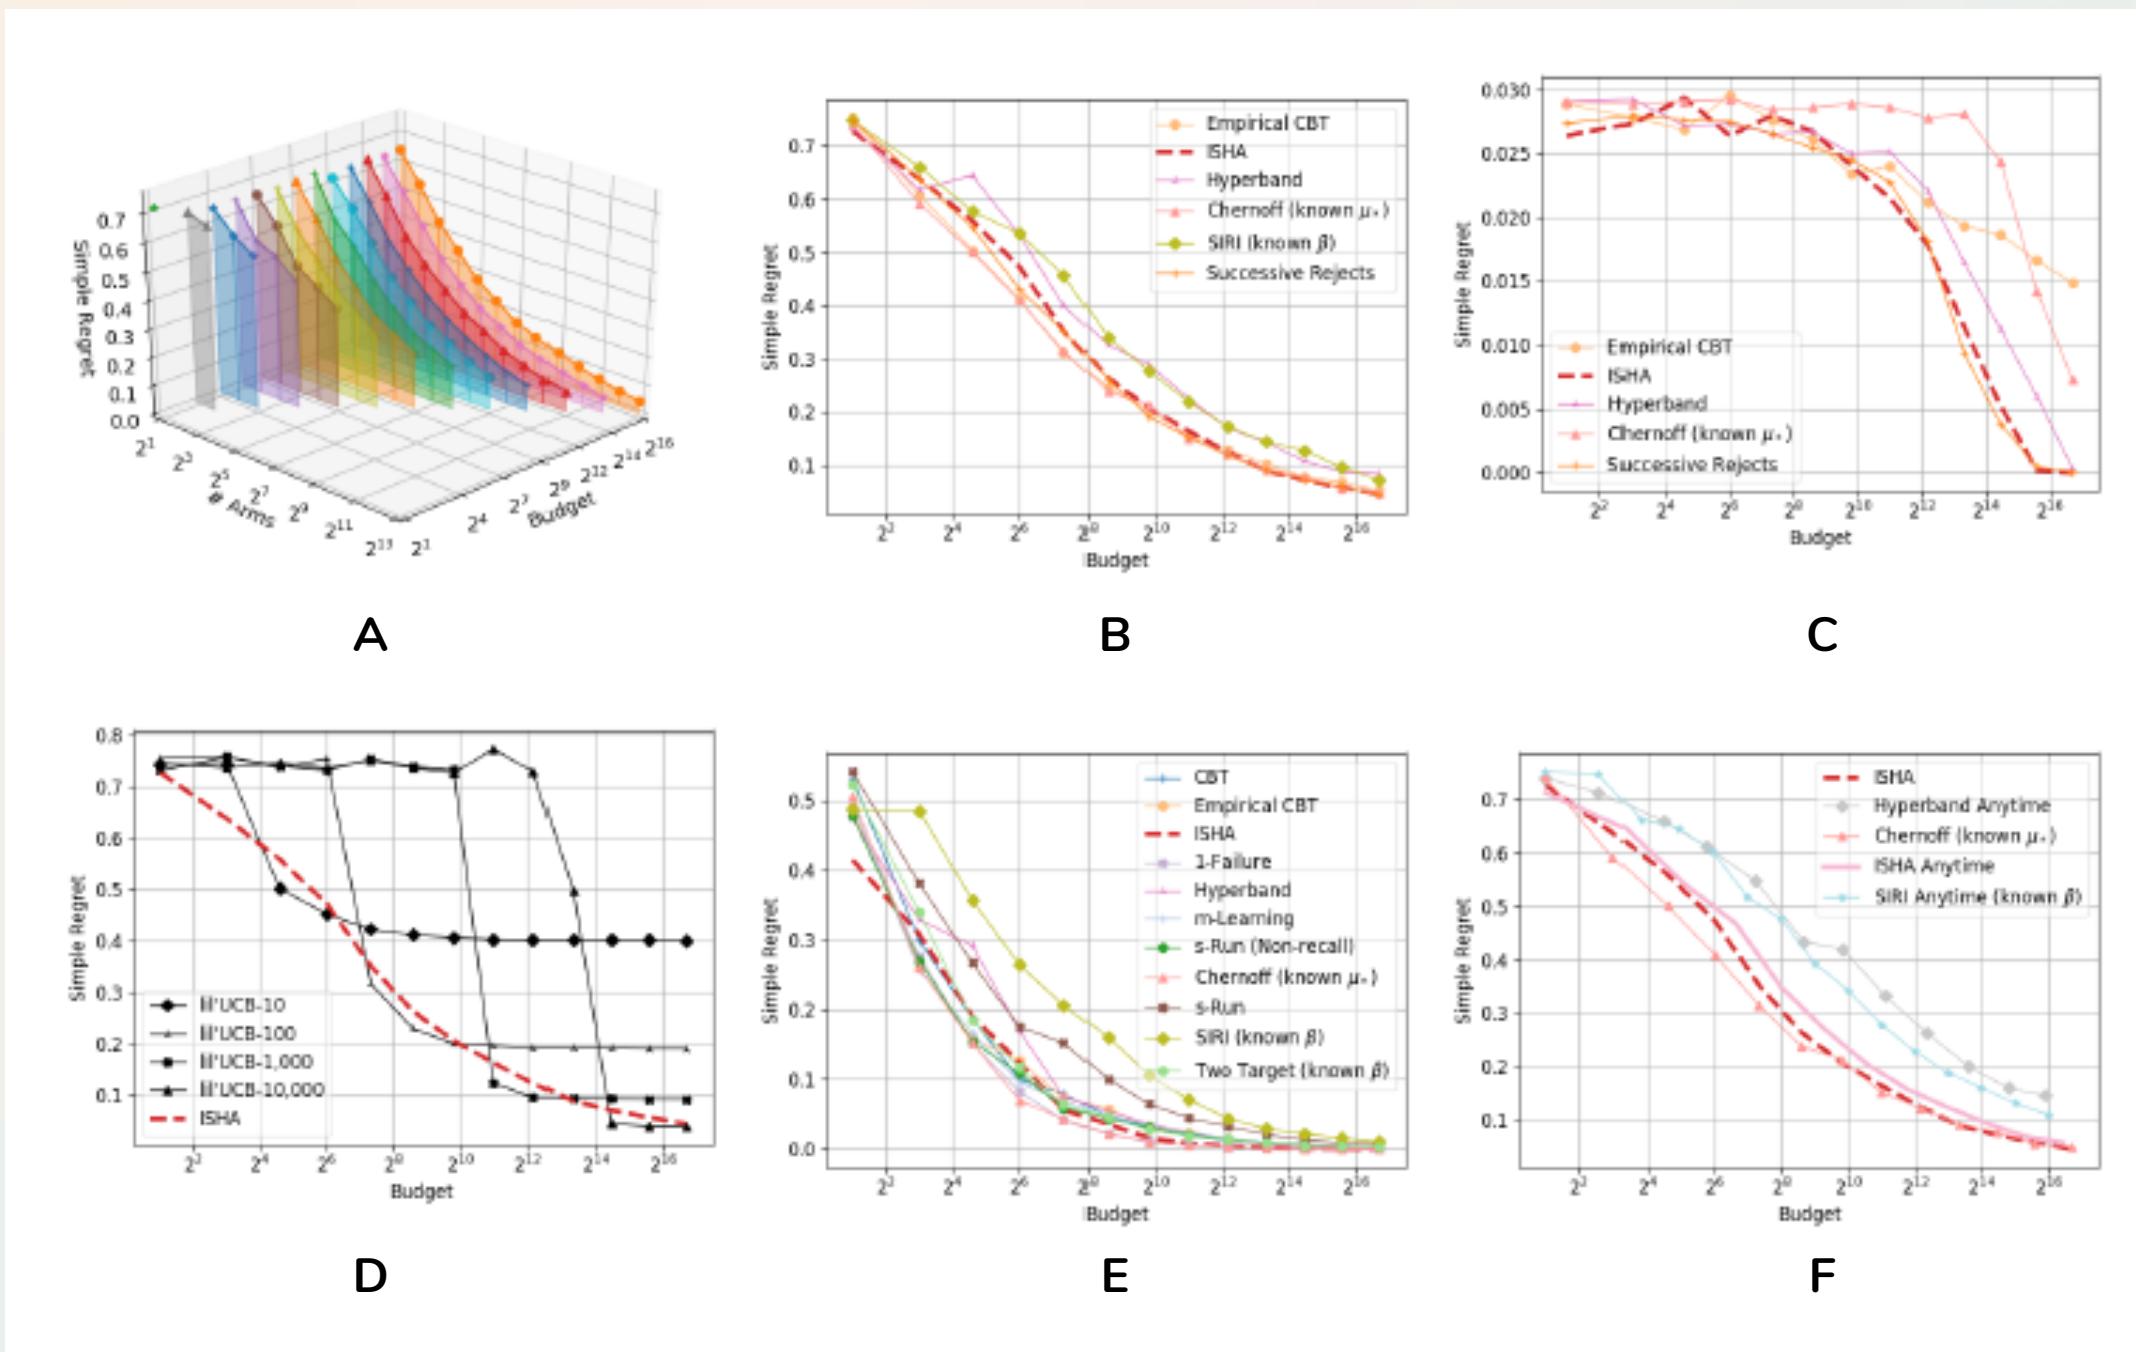
ISHA



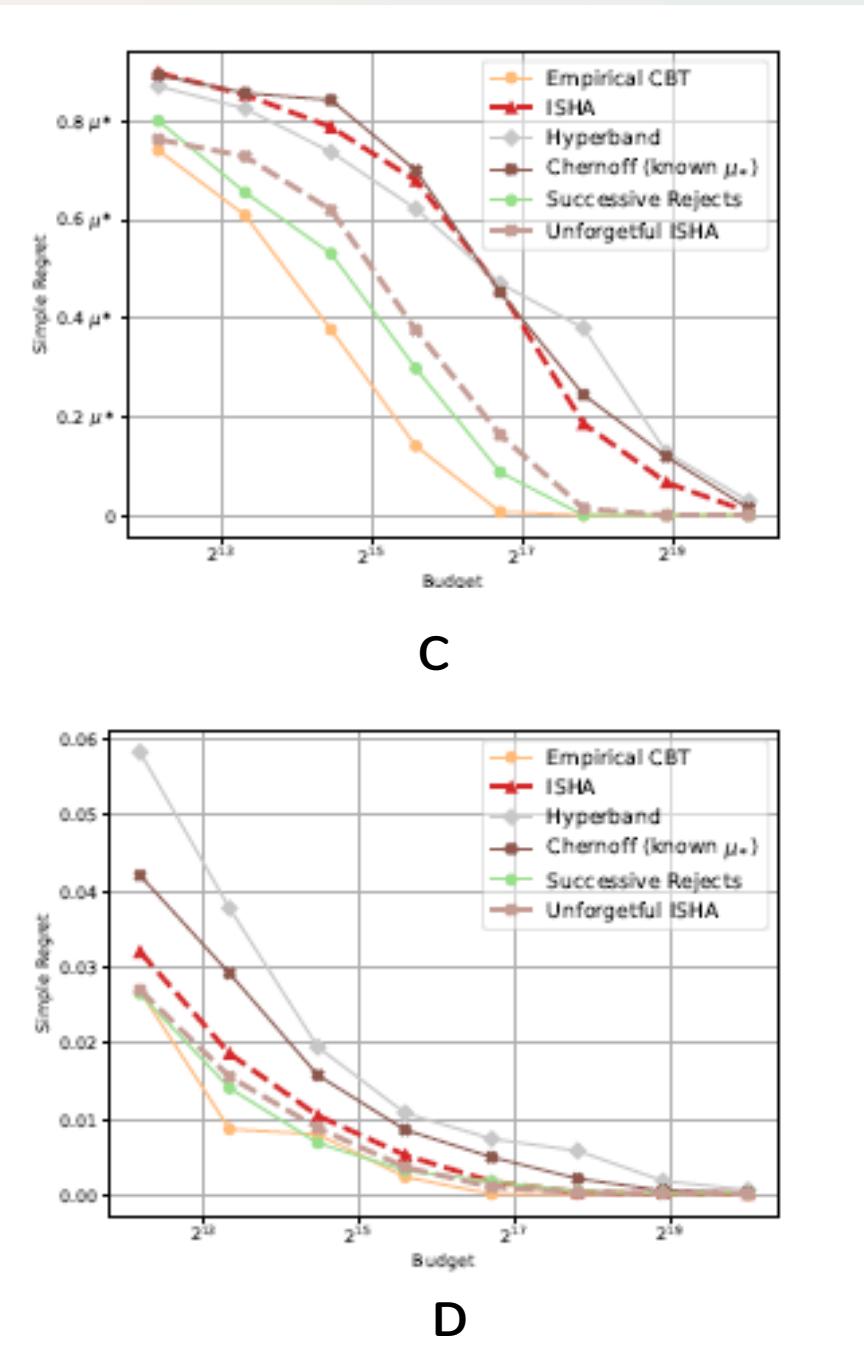
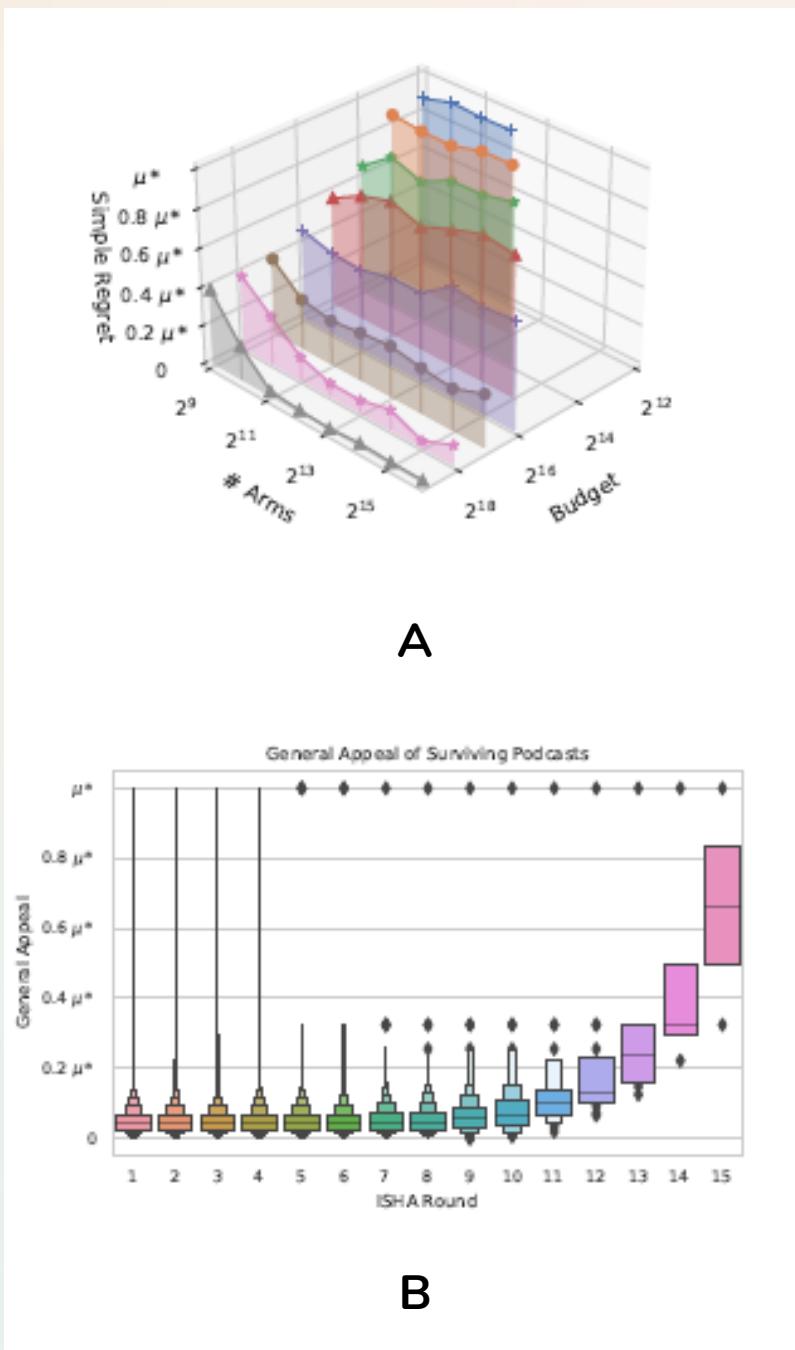
ISHA



Experimentos



ISHA frente a nuestro problema



¿Por qué UISHA?



Delayed
Rewards



Consideraciones de
Ingenieria



Conclusiones

- Identificar un podcast prometedor es difícil.
- Consumption-based features. No aportan al objetivo.
- ISHA, una solución aceptable para nuestro problema.

Referencias

- Aziz, M., Anderton, J., Jamieson, K., Wang, A., Bouchard, H., & Aslam, J. (2022, September). Identifying new podcasts with high general appeal using a pure exploration infinitely-armed bandit strategy. In Proceedings of the 16th ACM Conference on Recommender Systems (pp. 134-144).
- Li, L., Jamieson, K., DeSalvo, G., Rostamizadeh, A., & Talwalkar, A. (2017). Hyperband: A novel bandit-based approach to hyperparameter optimization. *The journal of machine learning research*, 18(1), 6765-6816.
- Audibert, J. Y., Bubeck, S., & Munos, R. (2010, June). Best arm identification in multi-armed bandits. In COLT (pp. 41-53).
- Carpentier, A., & Valko, M. (2015, June). Simple regret for infinitely many armed bandits. In International Conference on Machine Learning (pp. 1133-1141). PMLR.
- Mukherjee, S., Tripathy, A., & Nowak, R. (2020). Generalized Chernoff sampling for active learning and structured bandit algorithms. *stat*, 1050, 15.
- Chan, H. P., & Hu, S. (2018). Infinite arms bandit: Optimality via confidence bounds. *arXiv preprint arXiv:1805.11793*.
- Bonald, T., & Proutiere, A. (2013). Two-target algorithms for infinite-armed bandits with bernoulli rewards. *Advances in Neural Information Processing Systems*, 26.