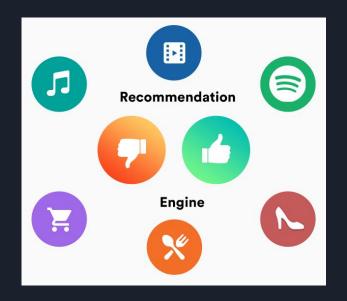


Grupo 14 RecSys 23-2 Álvaro Postigo Martín Ocqueteau Sara Godoy Rodrigo Ogalde

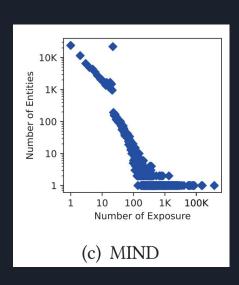
#### Introducción

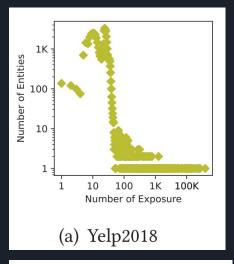
- Importancia de los sistemas.
   recomendadores en la actualidad
- Benefician a las personas para reducir la sobrecarga de información.
- Se introduce el filtrado colaborativo, su evolución y su problemática.
- Presentación de grafos de conocimiento (KGs) para representar relaciones usuario-ítem.

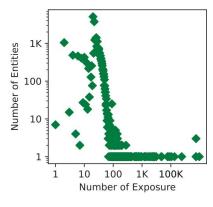


#### KG-aware

- Pueden ser eficientes, pero son vulnerables al ruido.
- En la práctica suelen ser dispersos y ruidosos.
- Muestran distribuciones largas y conexiones irrelevantes entre usuario - entidad.
- Se presentan 2 perspectivas:
  - Vista local: Agregar información directamente de entidades de baja calidad introduce ruido.
  - Vista global: La agregación de información en el KG puede ser excesivamente suavizada.



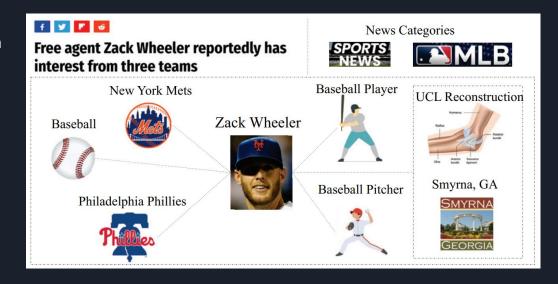




(b) Amazon-Book

### Ejemplo y descripción entidades "ruidosas"

- Ejemplo ilustrativo.
- Se muestra que información como lugar de nacimiento y cirugías son entidades poco relevantes que generan "ruido".



### KGCL Mecanismo e inspiración

- Mecanismo de agregación de conocimiento consistente.
- Esquema de aprendizaje contrastivo de vista cruzada.
- Se utiliza la relación semántica externa del ítem.
- Se suprime el ruido del KG.

- Inspirada en el aprendizaje de KGs y ampliación de datos auto supervisada.
- Su objetivo es refinar las representaciones usuario-ítem.
- El modelo aprende a descartar tripletas y data irrelevante el KG.
- Puede integrarse en diversos modelos.

#### Preliminar

#### Escenario de recomendación:

- Tenemos un conjunto de usuarios (U) y un conjunto de ítems (I).
- Se utiliza una matriz de interacción usuario-ítem (Y) para representar los comportamientos de consumo de los usuarios con diferentes ítems.
- Si un usuario ha interactuado con un ítem (por ejemplo, haciendo clic, revisando o comprando), el elemento de la matriz es 1; de lo contrario, es 0.

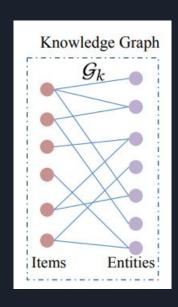
#### Grafos de interacción y conocimiento:

- A partir de la matriz Y, se construye un grafo de interacción usuario-ítem (Gu).
- Se introduce un grafo de conocimiento (Gk) que organiza atributos externos de ítems con diferentes tipos de entidades y relaciones.
- Ejemplo: (Titanic, Dirigido por, James Cameron) para recomendaciones de películas.

### Metodología

#### Metodología: Relation-aware Knowledge Aggregation

1. Knowledge Aggregation with Relation Heterogeneity



$$\mathbf{x}_{i}$$
 = Vector Item  $\mathbf{x}_{e}$  = Vector Entidad  $\mathbf{x}_{i} = \mathbf{x}_{i} + \sum_{e \in \mathcal{N}_{i}} \alpha\left(e, r_{e,i}, i\right) \mathbf{x}_{e}$ 

Conexiones  $\alpha\left(e, r_{e,i}, i\right)$ 

#### Metodología: Relation-aware Knowledge Aggregation

1. Knowledge Aggregation with Relation Heterogeneity

$$x_i = Vector Item x_e = Vector Entidad$$

$$\mathbf{x}_{i} = \mathbf{x}_{i} + \sum_{e \in \mathcal{N}_{i}} \alpha \left( e, r_{e,i}, i \right) \mathbf{x}_{e}$$

W = Matriz de Pesos Parametrizada

$$\alpha\left(e, r_{e,i}, i\right) = \frac{\exp\left(LeakyReLU\left(\mathbf{r}_{e,i}^{\top}\mathbf{W}\left[\mathbf{x}_{e} \| \mathbf{x}_{i}\right]\right)\right)}{\sum_{e \in N_{i}} \exp\left(LeakyReLU\left(\mathbf{r}_{e,i}^{\top}\mathbf{W}\left[\mathbf{x}_{e} \| \mathbf{x}_{i}\right]\right)\right)}$$

#### Metodología: Relation-aware Knowledge Aggregation

#### 2. Semantic Representation Enhancement

$$\mathcal{L}_{TE} = \sum_{(h,r,t,t') \in \mathcal{G}_k} -\ln \sigma \left( f_d(\mathbf{x}_h,\mathbf{x}_r,\mathbf{x}_{t'}) - f_d(\mathbf{x}_h,\mathbf{x}_r,\mathbf{x}_t) \right)$$

$$f_d = \|\mathbf{x}_h + \mathbf{x}_r - \mathbf{x}_t\|$$

$$x_h = Vector "Head"$$

$$x_r = Vector Relacion H-T$$

$$x_h + x_r$$
 debiera ser similar a  $x_t$ 

$$x_{t} = Vector "Tail"$$

$$x_{t'}$$
 = Vector de objeto al azar

### Metodología: Knowledge - Guided Contrastive Learning

- Interaction Graph Augmentation Mechanism
- Knowledge-aware Co-Contrastive Learning

#### Metodología: <u>Knowledge</u> Graph Augmentation

#### 1. Augmentation on Knowledge Graph Structures

- Busca maximizar la información mutua entre vistas aumentadas y regularizar el aprendizaje de incrustaciones con objetivos contrastivos.
- La propuesta del KGCL se basa en generar diferentes vistas de estructuras d KGs, ademas de una discriminación auto-entidad

$$\eta_1(\mathcal{G}_k) = ((e, r, i) \odot \mathbf{M}_k^1), \ \eta_2(\mathcal{G}_k) = ((e, r, i) \odot \mathbf{M}_k^2)$$

#### Metodología: <u>Knowledge Graph Augmentation</u>

#### 2. Agreement between Augmented Structural Views

- Obtención de dos vistas de dependencia del KG con operadores  $\eta 1(\cdot)$  y  $\eta 2(\cdot)$ .
- *ci* representa la consistencia estructural del ítem *i*.
- fk es el esquema de agregación de conocimiento consciente de la relación.
- Genera incrustaciones de ítems x1i y x2i para diferentes vistas estructurales aumentadas.
- $s(\cdot)$  es la función coseno para estimar la similitud entre x1i y x2i.

$$c_i = s\left(f_k\left(\mathbf{x}_i, \eta_1(\mathcal{G}_k)\right), f_k\left(\mathbf{x}_i, \eta_2(\mathcal{G}_k)\right)\right)$$

#### Metodología: Interaction Graph Augmentation Mechanism

$$w_{u,i} = \exp(c_i); \ p'_{u,i} = \max\left(\frac{w_{u,i} - w^{min}}{w^{max} - w^{min}}, p_\tau\right)$$
$$p_{u,i} = p_a \cdot \mu_{p'} \cdot p'_{u,i}$$
 (5)

$$\varphi(\mathcal{G}_u) = (\mathcal{V}, \mathbf{M}_u^1 \odot \mathcal{E}), \ \varphi(\mathcal{G}_u) = (\mathcal{V}, \mathbf{M}_u^2 \odot \mathcal{E})$$
 (6)

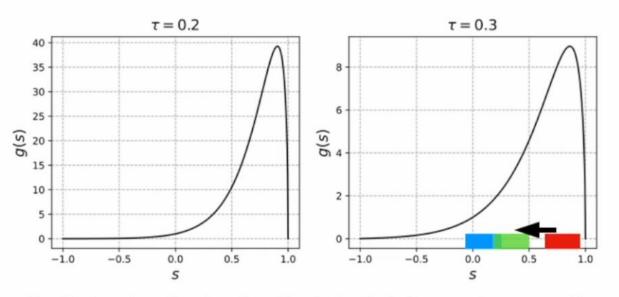
### Metodología: Knowledge-aware Co-Contrastive Learning

- Mejora robustez
- Vistas contrastivas
- Grafos colaborativos
- Pérdida de optimización

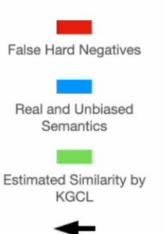
$$\mathcal{L} = \mathcal{L}_b + \lambda_1 \mathcal{L}_c + \lambda_2 \|\Theta\|_2^2, \tag{10}$$

### Metodología: Model Analysis of KGCL

$$g(s) = \sqrt{1 - s^2} \exp\left(\frac{s}{\tau}\right)$$



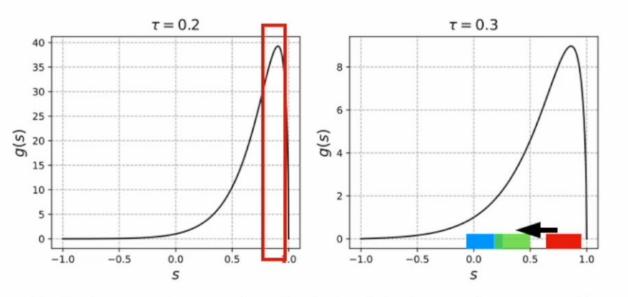
Distribution of gradient function g(s). s is the similarity score between positive and negative instances. Hard negatives significantly impact gradient.



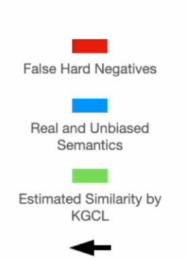


### Metodología: Model Analysis of KGCL

$$g(s) = \sqrt{1 - s^2} \exp\left(\frac{s}{\tau}\right)$$



Distribution of gradient function g(s). s is the similarity score between positive and negative instances. Hard negatives significantly impact gradient.



Knowledge Denoising

### Metodología: Model Analysis of KGCL

Al mejorar la discriminación sobre hard negatives, se mejora la precisión del gradiente usado para el aprendizaje enKnowledge-aware Recommender Systems de dos formas:

1. Los ítems conectados con entidades ruidosas son mejor diferenciados al hacer dropout de tripletas ruidosas.

2. Los usuarios que interactuaron con ítems ambiguos pueden ser modelados con similaridades más bajas, para que tengan un menor efecto sobre el gradiente.

## Experimentos

## Experimentos: Datasets

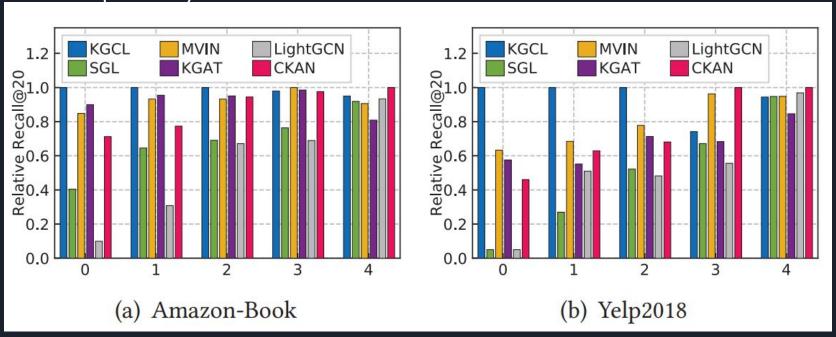


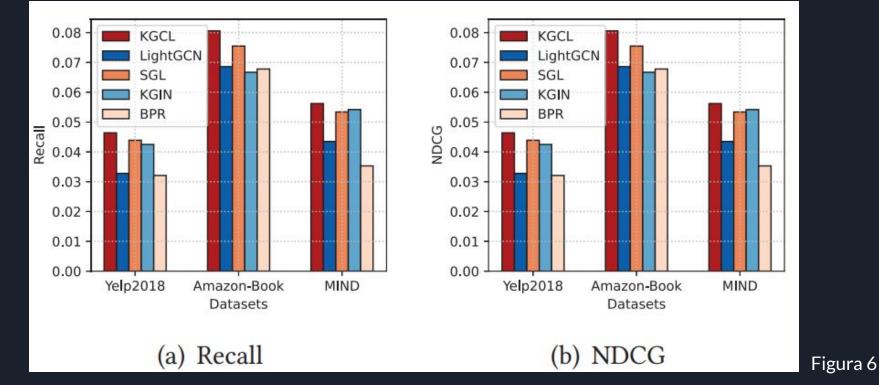




Stats.	Yelp2018	Amazon-Book	MIND
# Users	45,919	70,679	300,000
# Items	45, 538	24,915	48, 957
# Interactions	1, 183, 610	846, 434	2, 545, 327
Density Degree	$5.7 \times 10^{-4}$	$4.8 \times 10^{-4}$	$1.7 \times 10^{-4}$
		Knowledge Graph	
# Relations	42	39	90
# Entities	47, 472	29,714	106,500
# Triples	869,603	686, 516	746, 270

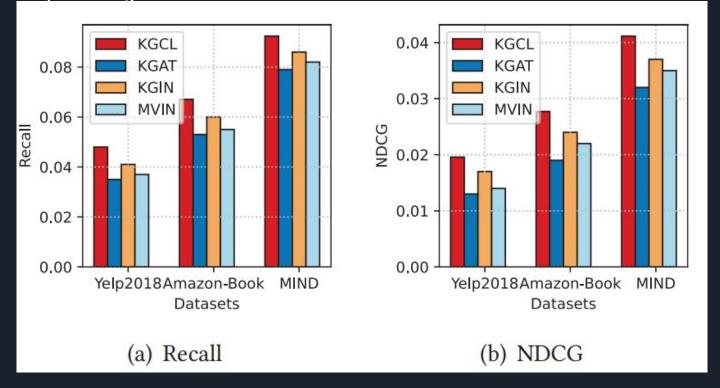






**Table 5: Performance in alleviating KG noise.** 

Model	Yelp2018		Amazon-book		MIND		Arres Doo
Model	Recall	NDCG	Recall	NDCG	Recall	NDCG	Avg. Dec.
KGAT	6.51%	0.0409	13.29%	0.0639	8.73%	0.0370	13.57%
KGIN	6.85%	0.0444	13.69%	0.0719	10.32%	0.0527	3.37%
MVIN	6.65%	0.0416	13.28%	0.0703	9.31%	0.0424	8.81%
KGCL	7.52%	0.0490	14.93%	0.0787	10.69%	0.0550	0.58%



# Experimentos: Ablation Study of KGCL Framework Impact of Knowledge-aware Graph Augmentation Schema

#### Dos variantes de KGCL:

 w/o KGA: Sin augmentation para el grafo de interacciones usuario-item. Se utiliza muestreo aleatorio de aristas para estimar información.

w/o KGC: Se elimina el componente Knowledge Graph Contrastive Learning del modelo.
 Se utilizan directamente los encodings de ítems al filtro colaborativo para el aprendizaje contrastivo.

# Experimentos: Ablation Study of KGCL Framework Impact of Knowledge-aware Graph Augmentation Schema

Table 3: Impact study of knowledge-aware graph augmentation schema with model variants of KGCL.

Model	Amazo	n-Book	MIND		
Model	Recall	<b>NDCG</b>	Recall	NDCG	
KGCL	14.96%	0.0793	10.73%	0.0551	
KGCL w/o KGA	14.85%	0.0788	10.57%	0.0546	
KGCL w/o KGC	14.68%	0.0771	10.35%	0.0537	

Table 4: Impact of  $\tau$  and  $\lambda_1$  on Amazon-Book dataset.

Metric	Recall@20								
$\lambda_1, \tau$	0.1	0.2	0.3	0.4	0.5				
$10^{-1}$	12.93%	14.96%	14.46%	13.94%	13.17%				
$10^{-2}$	13.74%	13.68%	13.08%	12.39%	11.55%				
$10^{-3}$	12.77%	11.94%	11.27%	10.62%	9.97%				

# Experimentos: Ablation Study of KGCL Framework Impact of Knowledge-aware Graph Augmentation Schema

Hyperparameter Sensitivity: Se evalúa el efecto de los hiper parámetros  $\lambda_1$  y  $\tau$ .

Table 4: Impact of $\tau$ and $\lambda_1$	on Amazon-Book dataset.
---	-------------------------

Metric	Recall@20								
$\lambda_1, \tau$	0.1	0.2	0.3	0.4	0.5				
$10^{-1}$	12.93%	14.96%	14.46%	13.94%	13.17%				
$10^{-2}$	13.74%	13.68%	13.08%	12.39%	11.55%				
$10^{-3}$	12.77%	11.94%	11.27%	10.62%	9.97%				

**Table 5: Performance in alleviating KG noise.** 

Model	Yelp	2018	Amazon-book		MIND		Arre Das
Model	Recall	NDCG	Recall	NDCG	Recall	NDCG	Avg. Dec.
KGAT	6.51%	0.0409	13.29%	0.0639	8.73%	0.0370	13.57%
<b>KGIN</b>	6.85%	0.0444	13.69%	0.0719	10.32%	0.0527	3.37%
MVIN	6.65%	0.0416	13.28%	0.0703	9.31%	0.0424	8.81%
KGCL	7.52%	0.0490	14.93%	0.0787	10.69%	0.0550	0.58%

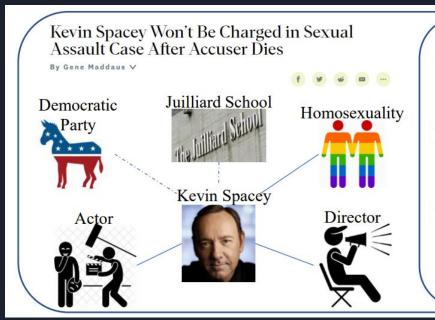
## Experimento: <u>Comparación</u> de eficiencia con SOTA

Table 2: Performance comparison of all methods on Yelp, Amazon and MIND. The superscript \* indicates the improvement is statistically significant where p-value < 0.01 level.

Model	Yelp	2018	Amazo	Amazon-book		ND
Model	Recall	NDCG	Recall	NDCG	Recall	NDCG
BPR	5.55%*	0.0375*	12.44%*	0.0658*	9.38%*	0.0469*
NCF	5.35%*	0.0346*	10.33%*	0.0532*	8.93%*	0.0436*
GC-MC	6.88%*	0.0453*	10.64%*	0.0534*	9.84%*	0.0491*
LightGCN	6.82%*	0.0443*	13.98%*	0.0736*	10.33%*	0.0520*
SGL	7.19%*	0.0475*	14.45%*	0.0766*	10.32%*	0.0539*
CKE	6.86%*	0.0431*	13.75%*	0.0685*	9.01%*	0.0382*
RippleNet	4.22%*	0.0251*	10.58%*	0.0549*	8.58%*	$0.0407^{*}$
KGCN	5.32%*	0.0338*	11.11%*	0.0569*	8.87%*	0.0431*
KGAT	6.75%*	0.0432*	13.90%*	0.0739*	9.07%*	$0.0442^{*}$
KGIN	7.12%*	0.0462*	14.36%*	0.0748*	10.44%*	0.0527*
CKAN	6.89%*	0.0441*	13.80%*	0.0726*	9.91%*	0.0499*
MVIN	6.91%*	0.0441*	13.98%*	0.0742*	9.62%*	0.0487*
KGCL	7.56%	0.0493	14.96%	0.0793	10.73%	0.0551

## Ahora como se ve esto en la práctica....

#### Case Studies : El efecto de KGCL en la práctica



News ranked w/o KGC

**Trump**: Transcript of 2nd call will "probably" be released Tuesday.

Life expectancy for **American** men keeps dropping.

Review **Police Use Of Force** In Wake Of Deadly Shooting... News ranked w/ KGC

**Cuba Gooding Jr.** faces new charge in groping case.

**Cuba Gooding Jr.** pleads not guilty to new sexual misconduct charges.

On opening night of the Modesto Junior College production of "The Hunchback of Notre Dame" last week,...

#### Case Studies : El efecto de KGCL en la práctica



News ranked w/o KGC

A contentious new paper traces the origins of modern humans to ancient wetlands in **Africa**.

A Hip New Natural Wine Bar Takes Over a Legendary East Hollywood Indian Restaurant.

**China**'s leaders to hold key conclave next week.

News ranked w/ KGC

Invest like Warren Buffett.

Trump's Trustbusters Bring Microsoft Lessons to **Big Tech** Fight.

Facebook launches a news section - and will pay publishers